Modelar el mundo

Analizando las consecuencias de lo inesperado, aleatorio y desconocido.

Daniel DB

2026-09-13

Table of contents

Prefacio **3**
Hoja de ruta . . . 3
Link del código de las simulaciones . . . 3
Apoyar este proyecto . . . 3
Disclaimer sobre el uso de inteligencia artificial . . . 4

1 Introducción **5**

2 Simulaciones **7**

I Simple vs complejo **12**

3 El promedio **13**
3.1 Cuando el promedio es el héroe . . . 14
3.2 Cuando el promedio es el villano . . . 19

4 Relaciones lineales **24**
4.1 Una corta explicación de mis modelos favoritos . . . 24
4.2 El país de las maravillas . . . 25
4.3 Cuando la crisis toca a tu puerta . . . 28

Prefacio

Esta es la versión web de mi libro: Modelar el mundo. Se trata de un libro técnico donde se utilizan simulaciones hechas en python para explorar el funcionamiento de modelos de machine learning considerando la aleatoriedad.

Hoja de ruta

Capítulo	Título	Estado
Capítulo 1	Introducción	**Publicado**
Capítulo 2	Simulaciones	**Publicado**
Capítulo 3	El promedio	**Publicado**
Capítulo 4	Relaciones lineales	**Publicado**
Capítulo 5	Relaciones no lineales	*En redacción (finales de Octubre 2026)*
Capítulo 6	Encontrar la simpleza	*Diseño conceptual*
Capítulo 7	Complejidad justificada	*Diseño conceptual*
Por definir	Irreducibilidad computacional	*Simulación terminada*

Link del código de las simulaciones

Repositorio en GitHub

Apoyar este proyecto

Si quieres apoyar este proyecto, puedes comprar la versión PDF del libro en Payhip. Descargar PDF en Payhip

Disclaimer sobre el uso de inteligencia artificial

Este libro fue escrito por un humano (yo) al 100%. Los conceptos que se exploran son el resultado de mi razonamiento y curiosidad. El uso de inteligencia artificial se limita a la generación del código para las simulaciones. Específicamente, utilicé Gemini flash con pensamiento extendido.

1 Introducción

Pavos esperando ser comidos

Esta analogía la extraigo del maestro Nassim Taleb. El pavo tiene la teoría de que los humanos lo aman porque lo alimentan todos los días. El pavo científico se presenta ante el comité de pavos pensadores y muestra abundante evidencia que respalda su teoría de que la humanida está hecha para servir a los pavos: los humanos les dan alimento, casa y protección; por ello, el pavo científico consigue reconocimiento. Guía a la sociedad de pavos en base a sus predicciones y alienta a su pueblo con grandes sueños para el futuro. Entonces, llega el día de acción de gracias y todos los pavos pierden la cabeza.

El pavo no puede entender el día de gracias, está fuera de su alcance. De igual manera, resolver el problema de la inducción está fuera del alcance de la humanidad. No importa cuánta evidencia acumulemos en favor de una teoría, nuestra ignorancia de la totalidad nos puede colocar en una posición peligrosa si depositamos demasiada confianza en nuestras predicciones.

El mundo actual maneja modelos complejos que están lejos de ser entendidos. Creemos que esa complejidad nos ayuda a entender mejor el mundo. Falso. Si no somos capaces de entender cómo funcionan los modelos, mucho menos podemos entender el mundo que están modelando.

En mis primeros años de universidad veía el milagro de las redes neuronales y pensaba que las máquinas serían capaces de resolver la ecuación del universo. Sin embargo, mi apetito intelectual de matemática y filosofía me llevó a la conclusión de que eso es imposible.

Ya que hoy vemos anuncios sobre inteligencia artificial general y tenemos tanto dinero apostado en favor de esta tecnología (tenemos como humanidad aunque se trate de una minoría de millonarios locos), la imagen que yo tenía en mi época universitaria se está volviendo un meme del público general. Parece que estos modelos complejos serán capaces de resolver la ecuación del universo.

Mis apuestas están en contra. Esto se debe a que un estudio serio de lo que somos capaces de explicar demuestra que realmente conocemos muy poco. Y no importa cuánta información tengamos, eso no mejora nuestro entendimiento. A veces lo empeora.

Tal vez, una máquina que usa el lenguaje, como los actuales LLMs, sea capaz de reducir la complejidad en algunos sectores importantes, pero hay áreas que son indomables. El objetivo de este libro es explorar esas áreas y entender cuáles son las consecuencias de una exploración ingenua.

Ya que los datos son tan importantes en el mundo actual, y se acumulan de manera compulsiva, más vale alertar sobre el peligro de convertirse en un pavo. Creer que se sabe algo provoca la toma de riesgos agresivos innecesarios. Cuando uno se sabe ignorante evita envalentonarse demasiado. Si creemos que entendemos lo inentendible, perderemos la cabeza el día de acción de gracias.

2 Simulaciones

La piedra filosofal

Una simulación nos permite alejarnos de lo abstracto y tocar lo complejo. Esta herramienta es la columna vertebral del libro y por eso es importante empezar por aquí.

Usemos un ejemplo simple: lanzar una moneda.[1] Todos sabemos que existe una probabilidad $p = 0.5$ de obtener `cara` o `cruz` (ambas opciones son igualmente probables), y en este ejemplo `cara` cuenta como un éxito. Ahora, yo pregunto: ¿cuál es la cantidad máxima de éxitos seguidos que podemos obtener al realizar diez lanzamientos? Esto se puede resolver de forma analítica con multiplicaciones y potencias, pero ese camino no le interesa a nadie.

Lo más divertido que podemos hacer es programar una moneda y lanzarla. Hacemos diez lanzamientos para un experimento y repetimos el experimento mil veces. Con esto, vamos a tener una buena aproximación a la distribución de probabilidad de obtener n éxitos seguidos.

Tenemos una moneda digital que obtiene `cara` o `cruz` con una probabilidad del 50%. Vamos a realizar 10 lanzamientos como podemos ver en la figura 2.1, y luego hacemos este mismo proceso durante mil experimentos para contar cuántos éxitos seguidos obtuvimos (figura 2.2). Finalmente, vamos a ver la distribución de esas rachas para ver el máximo de éxitos seguidos que podemos esperar si lanzamos una moneda 10 veces.



Figure 2.1: Lanzar una moneda 10 veces

El resultado es que después de mil experimentos vamos a poder contar cuántas veces aparecieron n éxitos seguidos, dividirlo entre mil y tener una probabilidad aproximada:

[1] Esto puede parecer mucho, pero antes de lanzar tu hamburguesería considera que tener un par de empleados, la renta del local, y otros improvistos que incluyen impuestos, seguros y gastos sorpresa; reduce tu ganancia personal a unos $800 si tienes suerte.

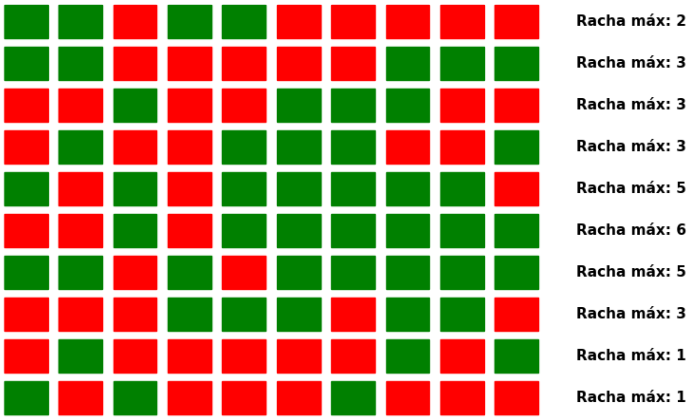


Figure 2.2: Repetición del experimento para contar la racha máxima

$$\hat{P}(\text{racha de } n) = \frac{f(n)}{1000}\,,$$

donde $\hat{P}$ es la probabilidad aproximada de obtener n éxitos seguidos, y $f(n)$ es la frecuencia de nuestras rachas (cuántas veces apareció esa racha en los experimentos).

Antes de mostrarte las probabilidades me gustaría preguntarte qué tan probable crees que es obtener sólo éxitos en 10 lanzamientos. Dame un número del 1 al 100. Espero que lo tengas en mente cuando te revele la verdad. En la figura 2.3 puedes ver el resultado de la simulación. La probabilidad de obtener `cara` más de 5 veces seguidas se vuelve casi imposible, menos del 5%. Lo más probable es obtener 2 y 3 éxitos seguidos, hasta 4 resulta razonable, pero más allá de esos valores, estamos en el mundo de la fantasía.

Hay un acertijo que pregunta ¿cuál es la probabilidad de obtener `cara` si ya lanzamos una moneda 10 veces y todas salieron `cara`?, y la gente se siente tentada a decir que lo más probable es que salga `cruz`, para estabilizar la cuenta. Con una moneda normal, sabemos que la probabilidad se mantiene en 50%, porque cada lanzamiento es independiente. No importa si ya obtuviste `cara` 10 o 100 veces, la moneda no lleva la cuenta. Sin embargo, con lo poco probable que es obtener 10 éxitos consecutivos, podemos empezar a dudar de que se trate de una moneda normal. Se vuelve viable que se trate de una moneda cargada.

Aunque el acertijo se haga para un entorno teórico perfecto, nosotros no vivimos en un mundo teórico perfecto. Si una moneda se lanza 10 veces y sale `cara` 10 veces, ahí hay truco. De hecho, podemos hacer una nueva simulación con monedas cargadas para ver qué tan probable es obtener 10 éxitos seguidos si tenemos una moneda que salta a nuestro favor.

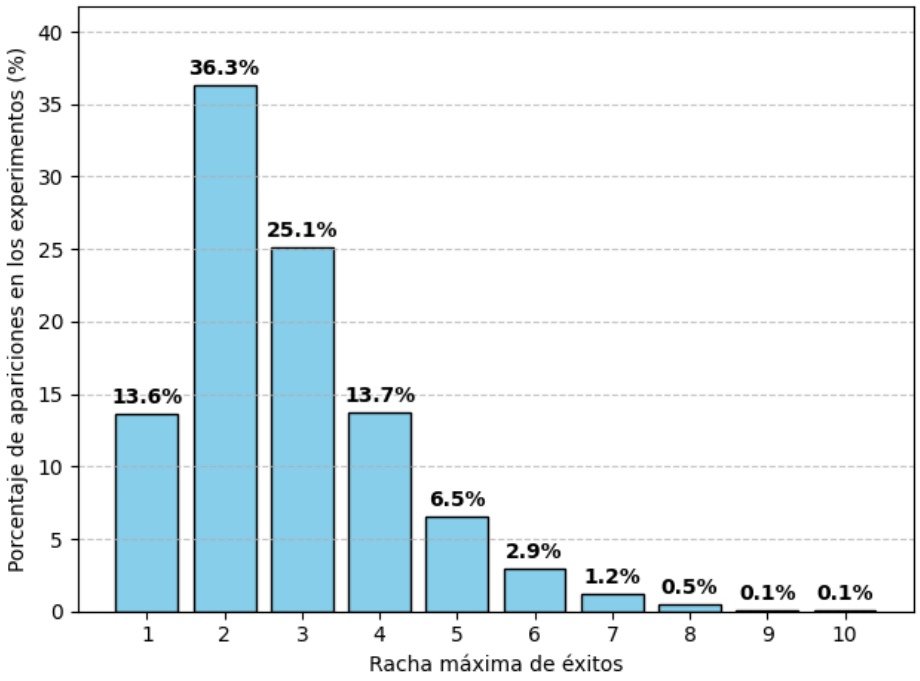


Figure 2.3: ¿Cuántos éxitos seguidos puedo conseguir si lanzo una moneda 10 veces?

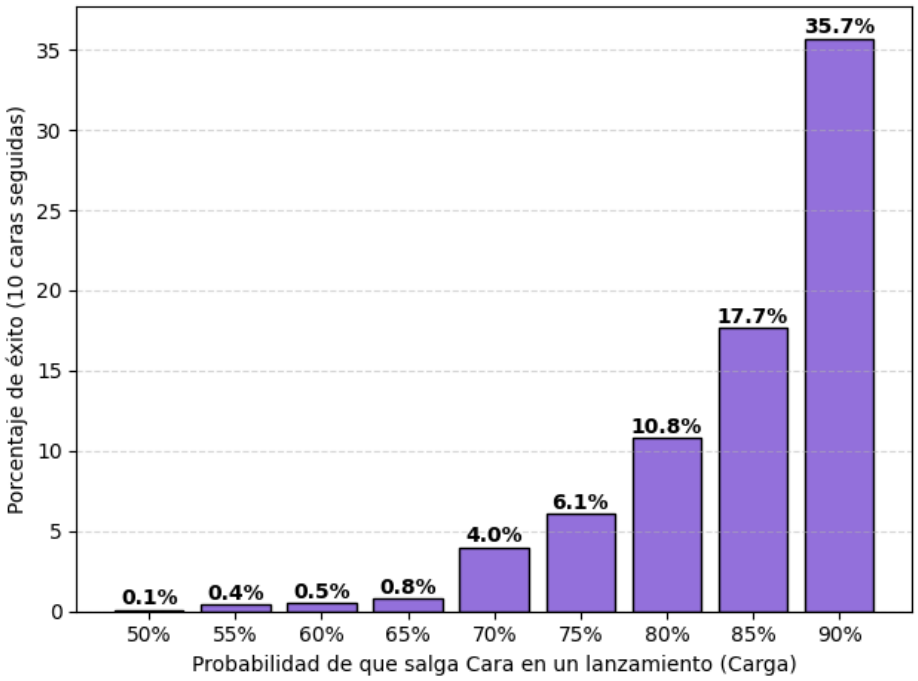


Figure 2.4: ¿Qué tan probable es obtener 10 éxitos consecutivos con monedas cargadas?

Los resultados están en la figura 2.4. Observa que incluso con una carga del 90% ($p_{\text{cara}} = 0.9$), obtener 10 éxitos consecutivos apenas alcanza la probabilidad del 35%. Por lo que si alguien te pregunta qué es más probable, que salga `cara` o `cruz`, después de que salió cara 10 veces seguidas, puedes decir con mucha confianza que lo más probable es que salga `cara`, porque la moneda debe estar cargada para obtener esos resultados.

De esta manera cerramos el capítulo, hemos observado el poder de las simulaciones, y también he establecido mi intención con este libro: hay que analizar los problemas más allá del escenario teórico que no se presenta nunca. Si el acertijo de arriba fuera una apuesta con sumas importantes de dinero, el teórico que se pasa de listo diciendo que la moneda no lleva la cuenta iría a la quiebra. Nuestra intuición nos dice que algo anda mal con obtener 10 éxitos seguidos, hay que escucharla. Sobrevivir es más importante que tener la razón.

Para finalizar, quiero agregar que otra ventaja de hacer simulaciones es que nos permite construir un entorno de conocimiento completo, donde sabemos todo lo que se puede saber sobre él, a diferencia de lo que pasa en el mundo real. Entonces, como conocemos la respuesta verdadera que oculta la aleatoriedad, podemos comparar el resultado de los modelos con la realidad más exacta. Lo cual no ocurriría si usáramos datasets abiertos de internet, porque no conocemos la distribución que sigue el mundo y cualquier estimación que hagamos puede meternos en el problema del pavo. No importa qué índice de error usemos para medir los resultados de un modelo, sólo contamos con lo que hemos observado. Por otro lado, una simulación nos ofrece algo sólido para medir nuestros modelos y ver cuáles sobreviven. Y ya que la vida no nos permite ver sus secretos, podemos asumir que un modelo que se comporta mal en una simulación va a ser peor en el mundo real.

Part I

Simple vs complejo

3 El promedio

Ingenuidad y manipulación

El promedio es la herramienta estadística más conocida, y también nos resulta la más natural, pues la usamos desde que entramos a la escuela. Nuestra experiencia con el promedio nos indica que puede usarse como resumen de un conjunto de datos, ya que si tienes un estudiante con un promedio de 9 sobre 10, concluyes que se trata de uno bueno sin necesidad de ver todo su historial.

Debido a esto, podemos llegar a malinterpretar lo que significa un promedio cuando se trabaja con datos que no muestran la estabilidad de las calificaciones escolares. Veamos un ejemplo de esta estabilidad. Si eras un chico que obtenía 8 en todas sus tareas y exámenes, un único 0 no causaba un colapso de tu nota final, como un 10 no te convertía en el mejor de la clase. Podemos verlo en este ejemplo:

$$\frac{8.5 + 8.25 + 7.75 + 9 + 7.5 + 8 + 8 + 8.5 + 7.75 + \mathbf{0}}{10} = \mathbf{7.33}\,,$$
$$\frac{8.5 + 8.25 + 7.75 + 9 + 7.5 + 8 + 8 + 8.5 + 7.75 + \mathbf{10}}{10} = \mathbf{8.33}\,.$$

Ir de un extremo al otro equivale a un punto de diferencia, lo cual puede parecer mucho cuando eres un niño que intenta impresionar a sus padres, pero en términos prácticos, se trata de ruido.

Las cosas cambian cuando hablamos de dinero, un tema que le interesa a todo el mundo. Ya que la distribución del dinero muestra enormes desigualdades, usar esta métrica es una estrategia de manipulación común para venderte sueños imposibles.

Un ejemplo clásico es este anuncio que me aparece en cada rincón de internet: obtén un sobresueldo de x dinero haciendo trading, o comprando esto, o vendiendo aquello. Cuando vas a los detalles te advierten que esos valores son el promedio obtenido de un grupo de pobres diablos que intentaron el mismo método inútil que quieren venderte. Veamos por qué se trata de una mentira.

Puedes tener a noventa y nueve personas con una ganancia anual nula y a una única persona con un aporte gigante de un millón:

$$\frac{99 \times 0 + 1\,000\,000}{100} = 10\,000\,.$$

Luego, podrías escuchar que el método te consigue una ganancia anual promedio de unos fabulosos \$10 000. Y concluyes (erróneamente) que lo mejor que puedes hacer es adquirir el curso que te están vendiendo.

Por eso, mi intención con este capítulo es abrirte los ojos ante la amenaza de darle demasiada importancia a un promedio si no conoces la naturaleza de la variable que estás analizando. No es lo mismo hablar de un promedio limitado por el mundo físico, que de uno que trabaja sobre sistemas de información.

3.1 Cuando el promedio es el héroe

Pongamos un ejemplo donde el promedio tiene sentido: queremos estimar el consumo medio diario de gramos de carne en un local de hamburguesas del barrio. Esto nos permite planificar gastos, y en este escenario tiene todo el sentido del mundo usar un promedio como estimador porque nunca vas a tener cien clientes que consuman una hamburguesa junto a uno que consuma mil.

Es posible que la estimación tenga pequeñas explosiones inesperadas (como tener el restaurante lleno), pero sigue estando limitado por un sistema físico (el tamaño del restaurante). No puedes pasar de cero a un millón en un minuto.

En este sentido, lo único que hace falta es la desviación estándar. Ninguna media tiene sentido sin su varianza. Bajo una campana de Gauss perfecta, tienes alrededor de un 68% de la información dentro de una desviación estándar hacia arriba y hacia abajo.

Para entenderlo mejor, hagamos una simulación. La cantidad de gramos que contiene cada hamburguesa está estandarizada: una hamburguesa normal tiene 125 g, una premium tiene 200 g, y una hamburguesa doble tiene 250 g.

Luego asignamos probabilidades razonables para cada hamburguesa: la probabilidad de que un cliente compre una hamburgusea normal es $p_{\text{hnormal}} = 0.5$, la de que compre una premium es $p_{\text{hpremium}} = 0.3$, y para llegar a 1, la de una hamburguesa doble tiene que ser $p_{\text{hdoble}} = 0.2$.

Esto signficia que cuando un cliente se para frente al cajero, tiene una probabilidad p_i de ordenar una de esas hamburguesas, donde $i \in \{\text{hnormal}, \text{hpremium}, \text{hdoble}\}$. Lo que se traduce en que la probabilidad de comprar una hamburguesa disminuye al incrementar el precio, algo que tiene todo el sentido del mundo.

Con estas probabilidades, utilizamos una distribución normal $\mathcal{N}(20, 5^2)$ para simular la entrada de clientes durante las 5 horas que el local está en funcionamiento. Esta distribución tiene una media de 20 con una desviación estándar de 5, y el local tiene una capacidad máxima de 30

clientes por hora. Esto significa que la mayor parte del tiempo, el local va a tener entre 15 y 25 clientes cada hora, pero si llega a tener más, nunca van a ser más que 30 (límites físicos).

Puedes entender esto gráficamente en la figura 3.1. La figura representa un único día de trabajo. La cantidad de clientes está relacionada con el consumo de carne, como es de esperarse, pero como la elección de los clientes también implica aleatoriedad, a veces puede haber menos clientes, pero más consumo de carne. En cualquier caso, podemos ver que el día inició con local lleno, tenemos 30 clientes, que es el máximo que puede haber cada hora. Luego, la cantidad de clientes baja, pero vemos que este día nunca llega a 10, lo cual resulta muy poco probable.

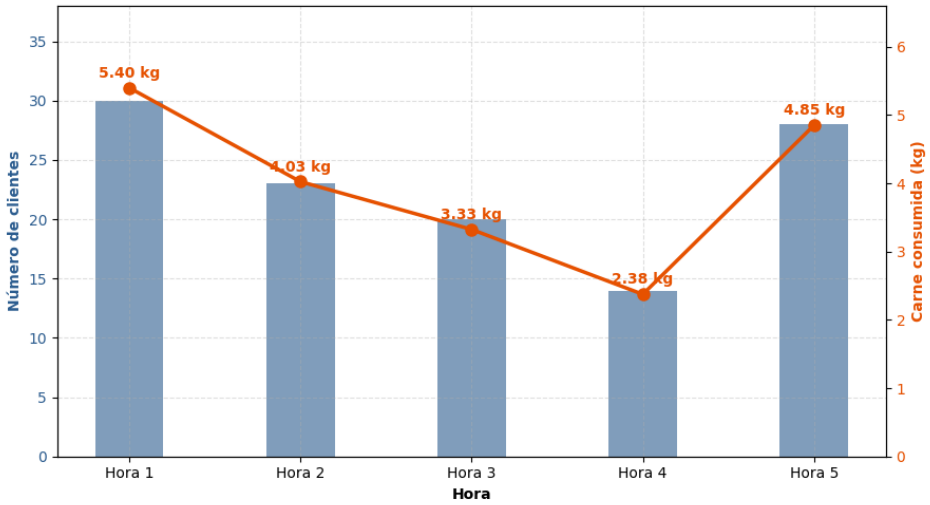


Figure 3.1: Simulación de un día de trabajo (5 horas).

Ahora podemos simular un mes y recopilar datos. Primero, tenemos un consumo diario individual:

$$C_d = \sum_{i=1}^{N} X_i \,,$$

donde C_d es el consumo total de gramos de carne de un día, N representa el número total de hamburguesas vendidas ese día, y X_i representa los gramos que contiene cada hamburguesa vendida (que puede ser normal, premium o doble según su probabilidad). Así, obtenemos valores de 30 días para calcular un promedio de consumo diario con su desviación estándar:

$$\bar{C} = \frac{1}{30} \sum_{d=1}^{30} C_d \,,$$

$$s = \sqrt{\frac{1}{30} \sum_{d=1}^{30} (C_d - \bar{C})^2} \,.$$

Es decir, durante cinco iteraciones (cinco horas de funcionamiento), generamos clientes de forma aleatoria que van a elegir una hamburguesa según su probabilidad p_i, luego sumamos

los gramos de carne que contiene cada hamburguesa elegida a un total de consumo diario C_d, y repetimos este experimento 30 veces para obtener los valores de un mes. Finalmente, calculamos el promedio diario con su desviación estándar para decidir cuánta carne vamos a comprar.

El resultado de esta primera simulación es visible en la figura 3.2, tenemos el total de carne consumida en kilos cada día. Esos valores los dividimos para 30 y obtenemos un promedio de 16.52 kg, con una desviación estándar de 1.87 kg. Puedes observar que el promedio junto a sus desviaciones estándar para arriba y para abajo consiguen abrazar a la mayoría de los valores obtenidos durante ese mes. Hay unos pocos picos hacia arriba y hacia abajo, pero esas excepciones tampoco se alejan demasiado de lo esperado. Esto es lo bello de trabajar en entornos físicos limitados que siguen las leyes del universo.

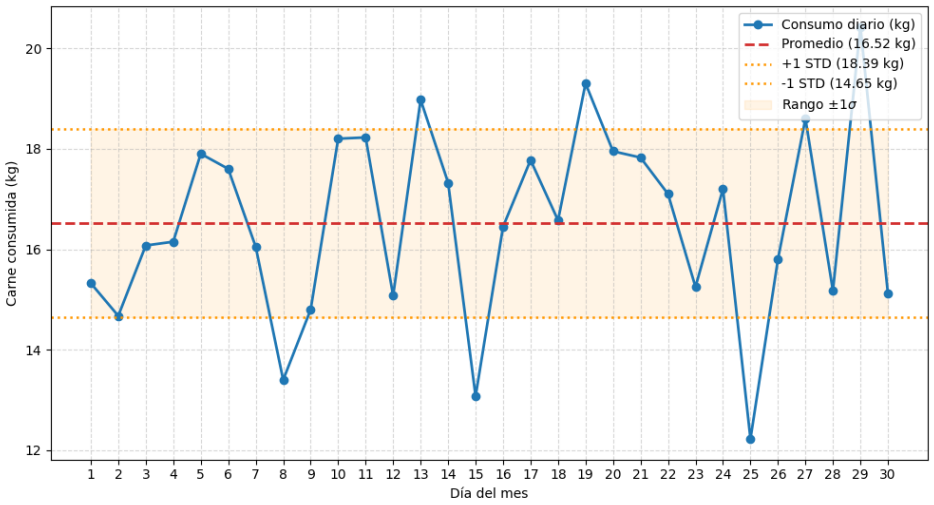


Figure 3.2: Simulación de un mes de trabajo.

Podemos imaginar estos datos como el monitoreo que hacemos de un local en el mundo real. Vemos cuántos clientes entran y cuántas hamburguesas se preparan durante un mes y obtenemos estos resultados: la media muestral es de 16.52 kg con una desviación estándar de 1.87 kg. Como la desviación es menor de 2 kg, creo que lo mejor es concentrarse en el promedio obtenido.

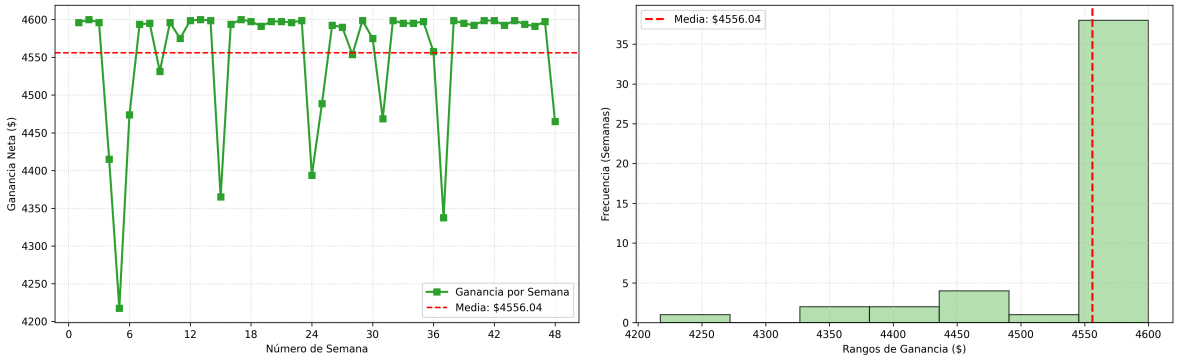
Ahora, debemos tomar una **decisión de negocio**: el resto del año vamos a comprar la carne de forma semanal, y vamos a comprar el valor promedio diario multiplicado por 7. Algo importate a tomar en cuenta es que en este mundo imaginario la carne sólo se vende por kilos enteros y cuesta $10 el kilo.

Entonces, tenemos que $16.52 \times 7 \approx 115$, por lo tanto, vamos a comprar 115 kg todas las semanas. Eso equivale a un gasto semanal de $1150. Finalmente, aplicamos la técnica del foodcost al 20% (los ingredientes representan el 20% del precio final del producto). Aunque sólo se venden kilos enteros, nosotros podemos estimar el valor de los gramos para nuestras

hamburguesas. Luego tomamos ese valor y lo multiplicamos por 5. Esto nos da como resultado que las hamburguesas van a costar:

$$
\begin{aligned}
1\ \text{kg} &= 1000\ \text{g}\,, \\
1\ \text{kg} &= 10\,\$\,, \\
1000\ \text{g} &= 10\,\$\,, \\
\text{precio_hnormal} &= \frac{125\ \text{g}}{1000\ \text{g}} \times 10\,\$ \times 5 = \mathbf{6.25}\,\$\,, \\
\text{precio_hpremium} &= \frac{200\ \text{g}}{1000\ \text{g}} \times 10\,\$ \times 5 = \mathbf{10.00}\,\$\,, \\
\text{precio_hdoble} &= 6.25\,\$ \times 2 = \mathbf{12.50}\,\$\,.
\end{aligned}
$$

Con estos precios, y estableciendo que el comportamiento de los clientes se va a mantener estable el resto del año, veamos qué tal le va a esta estrategia comercial. Vamos a analizar algunos puntos fundamentales para decidir si la estrategia funciona. ¿Estamos generando ganancias? Sin ganancias netas, nada tiene sentido. ¿Nos está sobrando carne? Porque si nos sobra mucha carne cada semana estamos comprando de más y desperdiciando recursos. Y finalmente, si no nos sobra, ¿se nos acaba rápido y nos obliga a cerrar el negocio? Tampoco resulta práctico comprar muy poco y fallarle a los clientes.



(a) Línea de tiempo de ganancias.

(b) Distribución de ganancias.

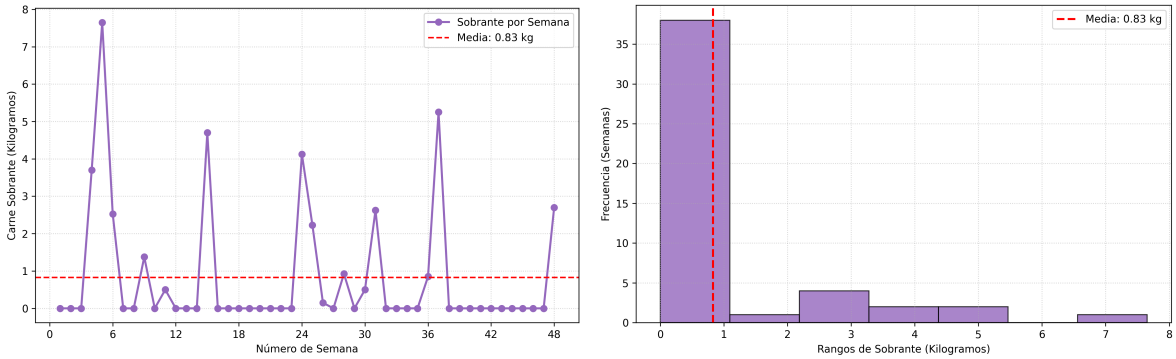
Figure 3.3: Ganancias netas durante un año de trabajo.

La figura 3.3 muestra las ganancias netas a lo largo del año y lo que tenemos es una ganancia constante que siempre supera los 4 mil dólares semanales.[1] Esto significa que usar el promedio como estimador por lo menos sí nos resulta rentable. No nos hizo falta analizar series de tiempo

[1]Esto puede parecer mucho, pero antes de lanzar tu hamburguesería considera que tener un par de empleados, la renta del local, y otros improvistos que incluyen impuestos, seguros y gastos sorpresa; reduce tu ganancia personal a unos $800 si tienes suerte.

ni aplicar estadística avanzada, un promedio centrado en factores físicos nos resultó confiable. También puedes ver que las ganancias ya no se comportan como una distribución normal. Tenemos un bloque altamente concentrado en la parte alta de las ganancias. Es decir, la mayor parte de las semanas la ganancia es superior al promedio de $\$4,523$, pero hay semanas donde la ganancia se cae. Veremos cómo nos afectan distribuciones asimétricas con valores extremos en más profundidad en el próximo escenario.

Ahora hay que analizar el consumo de carne. ¿Estamos comprando demasiado y podemos ahorrar unos dólares? La figura 3.4 nos muestra que la carne sobrante puede alcanzar algunos picos de 8 kilogramos, pero la mayor parte del tiempo, terminamos la semana sin nada. Esos pocos picos de sobras se pueden convertir en el almuerzo familiar o en una donación para los últimos clientes, la verdad es que no representan un problema considerando las ganancias.



(a) Línea de tiempo de la carne que sobra.

(b) Distribución de las sobras.

Figure 3.4: Cantidad de carne que sobra después de terminar la semana laboral.

Finalmente, la carne se nos acaba la mayor parte del tiempo, ¿pero tenemos suficiente para satisfacer a nuestros clientes todos los días? Primero hice un análisis de los datos generados para ver qué día de la semana se acababa la carne, todos los resultados dieron como respuesta el domingo. Así que podemos confiar en que la cantidad de carne que compramos es suficiente para cumplir con nuestra semana laboral. Si el domingo cerramos temprano por falta de ingredientes no podemos culparnos, el domingo es un día de relajación. La figura 3.5 nos muestra a qué hora suele terminarse la carne, podemos observar que sólo hubo un domingo en el que tuvimos que cerrar el local después de la primera hora. La mayor parte del tiempo la carne se termina en la hora 4 y 5, sobre todo en la 5. Es decir, las semanas que no nos sobra carne, podemos atender el local los domingos sin problema, si cerramos unos minutos antes, no pasa nada.

Con esto cerrramos nuestro primer escenario, ideal para el promedio. Ya que estamos tratando con variables limitadas por el mundo físico: carne que puede consumir un cliente y cantidad de clientes dentro del local, el promedio encuentra esa estabilidad que necesita para brillar. Ni siquiera tomamos en consideración las desviaciones estándar, usamos el modelo más simple posible. Y tal vez creas que se pueden mejorar las predicciones con un modelo más complejo,

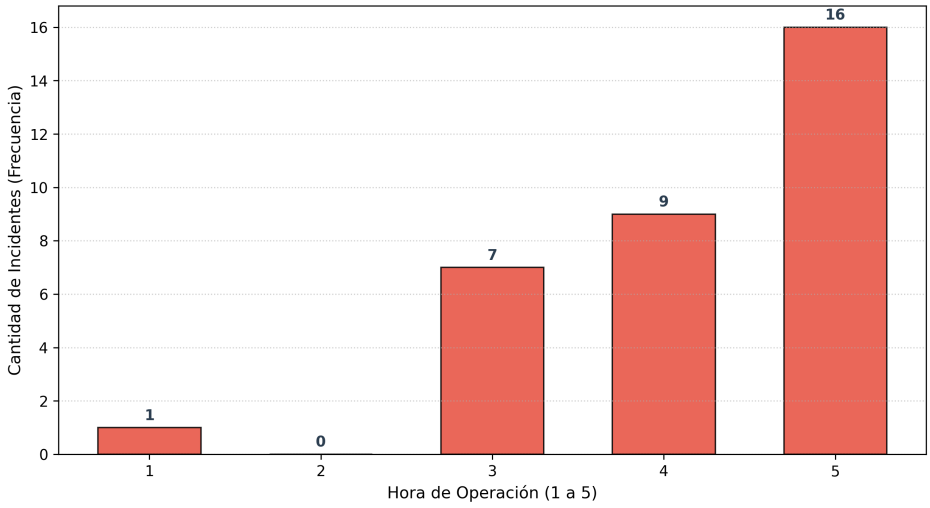


Figure 3.5: Hora a la que se termina la carne los domingos.

volveremos a esta cuestión más adelante, pero déjame adelantarte que no se puede. Por ahora, después de haber visto el promedio brillar, es momento de ver su caída.

3.2 Cuando el promedio es el villano

En nuestro siguiente escenario vamos a abandonar la seguridad del mundo físico y navegaremos los temibles y turbulentos mares de la información. Vamos a seguir con nuestro local de hamburguesas, para no romper la magia que creamos hace poco, y lo único que vamos a cambiar es el sistema para hacer los pedidos.

Queremos que nuestras hamburguesas nos den la libertad financiera, así que nos expandimos al mundo online para poder entregar pedidos hechos en aplicaciones de comida a domicilio. Igual que antes, queremos estimar cuánta carne debemos comprar cada semana. Igual que antes, hacemos un estudio preliminar del promedio de pedidos que se realizan en estas aplicaciones. La gran derrota es que no analizamos la distribución de esos pedidos.

El escenario está construido de esta manera. Las grandes cadenas de hamburguesas como McDonald's o Burguer King se llevan el 80% de los pedidos, mientras que los locales de barrio como el nuestro sólo se reparten el 20%. Esto es lo que se conoce como ley del 80/20. La competencia de barrio la dejé en 27 locales, parece un número razonable.

Luego, la cantidad de usuarios que hacen pedidos de hamburguesas por hora la modelé con una distribución normal $\mathcal{N}(150, 20^2)$, en general podemos esperar que haya entre 130 y 170 personas pidiendo hamburguesas cada hora. Sin embargo, la mayoría de esos usuarios (el 80%) va a realizar un pedido en una gran cadena. Esto significa que nosotros deberíamos pensar en

un promedio de $150 \times 0.2 = 30$ (¡repartidos entre 27 locales de barrio!), como un estimador sencillo, pero vamos a irnos por el lado ingenuo para demostrar que el promedio nos puede arruinar.

Dejemos correr la simulación y adoptemos el punto de vista del dueño de local ingenuo que mira una página de estadísticas de sitios web. Igual que en el escenario anterior, lo que queremos es un promedio diario para multiplicar por 7 y comprar la carne para la semana. Vemos una página de estadísticas web y nos enteramos de que se realizaron un promedio de 743 pedidos por día en el último mes. Con esa información lo que hacemos es dividir este número de pedidos para la cantidad de locales de hamburguesa que en hay la ciudad (incluyendo las grandes franquicias), y encontramos que debemos esperar unas 24 hamburguesas diarias ($743/30 = 24.77$).

Si esperamos 24 hamburguesas diarias, vamos a tener que comprar carne para llegar a 168 ($24 \times 7 = 168$). Digamos que en la aplicación sólo vamos a poner la hamburguesa normal, nada de premium ni doble, tenemos control sobre eso, y no queremos complicarnos la vida. Si nuestra hamburguesa normal tiene 125 g, entonces vamos a comprar 21 kg de carne cada semana ($125 \times 168 = 21\,000$). Ahora que hemos tomado nuestra decisión, veamos cómo nos va.

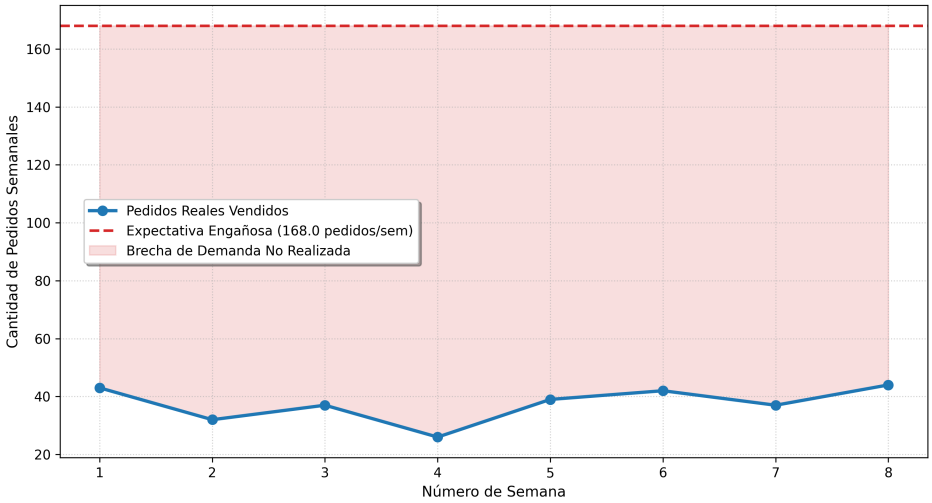
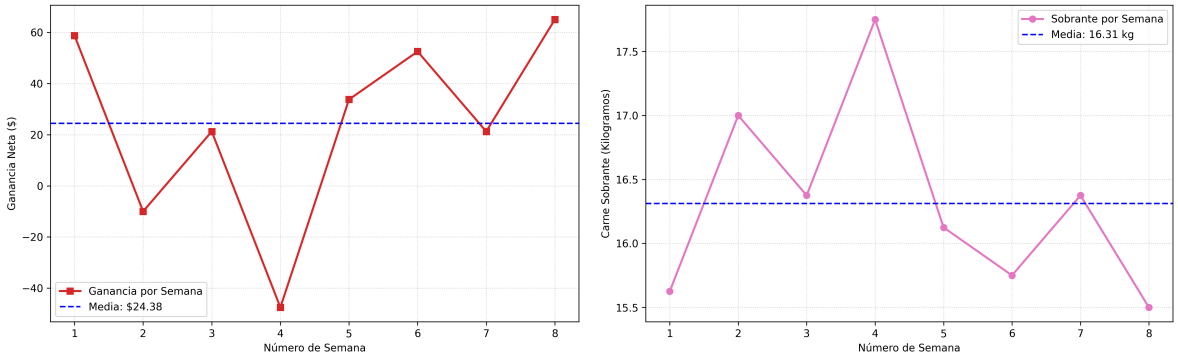


Figure 3.6: Diferencia entre nuestra expectativa y la realidad.

Nosotros esperábamos conseguir alrededor de 168 pedidos semanales, sin embargo, durante dos meses hemos visto cómo la realidad nos golpeaba semana a semana. Por ese motivo, detenemos el experimento y hacemos cuentas de los daños. La figura 3.6 nos muestra la diferencia entre nuestro estimador y los pedidos que conseguíamos en la aplicación. Nunca llegamos ni a la mitad de lo que habíamos estimado, lo cual, ya podemos deducir, se traduce en un desperdicio de comida y de dinero.

En la figura 3.7 podemos observar que nuestro estimador nos perjudicó de lo lindo. Por un



(a) Ganancias netas semanales.

(b) Kilos de carne sobrantes.

Figure 3.7: Resultados de nuestro estimador (promedio) ingenuo.

lado (figura 3.7a), vemos que nuestras ganancias no son constantes, de hecho, hay semanas en las que tenemos pérdidas considerables. Por el otro (figura 3.7b), tenemos más de 15 kg sobrantes cada semana. Con eso podemos hacer muchas hamburguesas y lo estamos tirando a la basura.

Curiosamente, cuando vemos el balance total de estos dos meses, tenemos una ganancia neta de $195.00. Esto es gracias a que el food cost al 20% es una estrategia que permite mantener un restaurante. Sin embargo, estos $195.00 extra (extra porque ya antendemos a nuestros clientes dentro del local con buenas ganancias) no justifican el desperdicio de comida. Además, existe la posibilidad de que hayamos tenido suerte, si el experimento seguía, íbamos a terminar con pérdidas.

¿Cómo hubiésemos podido evitar caer en esta trampa? Lo primero hubuiera sido entender la distribución de los datos. A diferencia de lo que pasaba en nuestro local de hamburguesas, los pedidos que se realizan en una aplicación no tienen limitaciones. Las grandes franquicias, debido a su popularidad, concentran la mayor parte de los pedidos, y no hay ningún límite físico o natural que evite que los usuarios soliciten todos sus pedidos a aquellas franquicias que les gustan, ignorando a todos los demás.

Como analistas, debemos ver cómo se reparten los datos más allá de un promedio diario. De haberlo hecho en este escenario, hubiéramos encontrado que, quitando las grandes franquicias, el resto de locales luchan por el 19.8% de los pedidos (figura 3.8).

Con esta información, como mínimo hubiéramos bajado nuestras expectativas. Como máximo, hubiéramos usado el promedio de pedidos repartido entre 28 locales ($27 + 1 = 28$ porque también consideraríamos el nuestro). Claro, antes de tomar esta decisión, hay que asegurarse de que no haya desigualdades entre estos 27 locales de barrio. La figura 3.9 nos muestra que, quitando las grandes franquicias, tenemos una distribución bastante uniforme donde algunos tienen un poco más, otros un poco menos, pero se ve cierta estabilidad en la cual podríamos confiar los primeros meses.

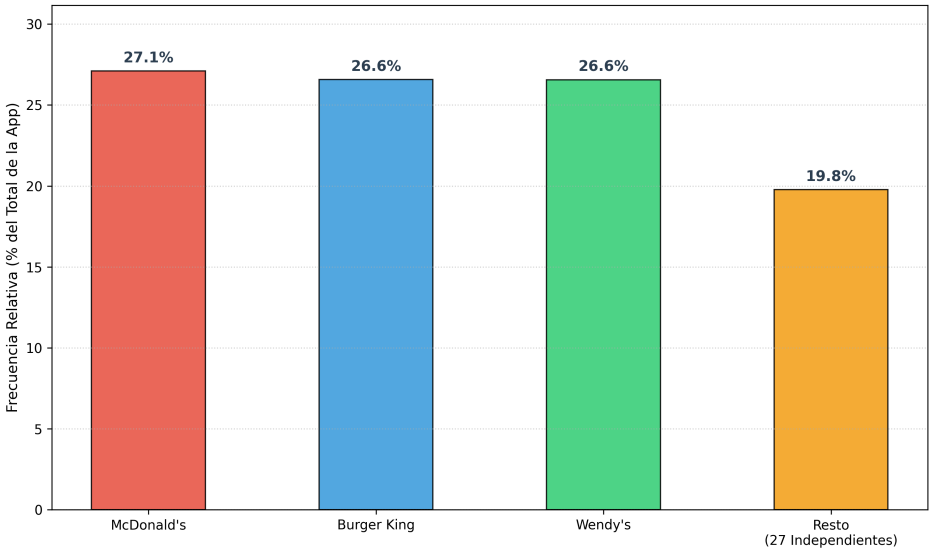


Figure 3.8: ¿Cómo se reparten los pedidos considerando las grandes franquicias?

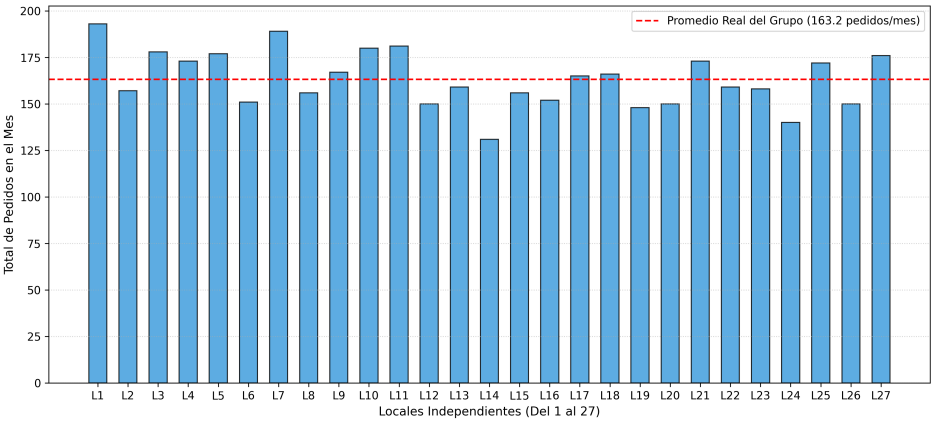


Figure 3.9: ¿Cómo se reparten los pedidos quitando las grandes franquicias?

Así nos despedimos de este gran capítulo. Nuestro primer capítulo usando simulaciones para entender las fortalezas y debilidades de un modelo estimador. De esta manera, espero dejar clara mi metodología, y que en los próximos capítulos podamos adentrarnos en los análisis de modelos más complejos, teniendo completamente claro en qué consiste una simulación.

4 Relaciones lineales

Es lineal o nada

Uno de los primeros descubrimientos que hice cuando inicié mi carrera en la publicación científica fue que los modelos más complejos no suelen justificar su complejidad. Una simple regresión lineal suele ser suficiente para la mayoría de los desafíos, y si no lo es, debes rezar para que los datos tan siquiera puedan ser modelados.

4.1 Una corta explicación de mis modelos favoritos

Los modelos que voy a usar en este capítulo van a aparecer en varias ocasiones y vale la pena que tengamos un marco de trabajo común en caso de que no los conozcas. No voy a adentrarme en definiciones profundas porque no es necesario, sólo hace falta entender por qué los seleccioné sobre todos los otros modelos que hay.

Primero tenemos un random forest (bosque aleatorio), se trata de un modelo que utiliza muchos árboles de decisión para obtener un estimado más robusto. Un árbol de decisión toma un conjunto de datos y lo divide para maxizar la predicción correcta de una característica. Por ejemplo, podemos tener un árbol que divide a los clientes de un banco según su riesgo crediticio. Un bosque aleatorio combina varios de estos árboles entregando muestras del dataset al azar para que cada árbol aprenda algo diferente. Luego se toman todos los valores predichos por los árboles y se hace un promedio. El random forest resulta ser una de las mejores opciones para casi cualquier problema. Recomiendo usarlo como base.

El XGBoost es una variación del bosque aleatorio que no me interesa mucho, pero es muy popular, mucha gente toma el XGBoost como modelo base. Yo prefiero el random forest, se supone que el XGBoost tiene unas cuantas ventajas, pero en mis investigaciones no ha hecho la diferencia.

Finalmente, la red neuronal es el modelo definitivo. Voy a usar un perceptron multicapa clásico sólo porque me interesa tener un modelo complejo para que compita con los más simples. Quizá en un capítulo futuro utilice otra arquitectura, pero por ahora no hace falta. Si no conoces el funcionamiento de una red neuronal, generalmente se suele tratar como una caja negra, donde las predicciones no se pueden interpretar del todo.

Sólo queda decir que si ordenamos los modelos por complejidad (qué tanto cómoputo requieren, qué cantidad de datos, y qué tan fácil es intrepretar sus resultados) podemos hacerlo de esta

manera: random forest (el más simple), XGBoost y la red neuronal (el más complejo). Con esta presentación es suficiente para seguir adelante.

4.2 El país de las maravillas

Empecemos con un escenario ideal. Tenemos una relación lineal completamente estable donde una variable independiente x genera una variable dependiente y, que involucra un factor de ruido aleatorio que sigue una distribución normal:

$$y = \beta x \left(1 + \frac{\epsilon}{100}\right) , \tag{4.1}$$

donde $\epsilon \sim \mathcal{N}(10, 5^2)$. Para evitar lo abstracto, imaginemos un escenario concreto. Como quiero usar una distribución normal, nuevamente debemos pensar en términos físicos. Vale la pena repetir que sería tonto asumir una distribución normal en un sistema de información.

El escenario que quiero presentarte es el siguiente: tenemos unas plantaciones agrícolas cuya producción queremos predecir para poder cerrar contratos por adelantado. Nuestro problema consiste en que necesitamos una cifra cerrada en cientos de kilos de producción para poder firmar un contrato. Es decir, el comprador nos exige garantizarle y_s cientos de kilos de producción para poder firmar el contrato. Si no cumplimos, recibimos una multa, pero también podemos producir de más y que ese producto no se venda porque el comprador no tiene la capacidad para manejar el excedente.

Entonces, la única información que tenemos es la cantidad de kilos de semillas que hemos plantado en nuestras tierras. Y la idea es predecir nuestros kilos de producción teniendo como entrada nuestros kilos de semillas sembradas. La producción puede ser cualquier cosa: café, sandías, maíz, arroz; no importa. Ya que tenemos un escenario anclado al mundo físico resulta razonable pensar en una relación lineal donde más kilos de semillas plantadas se traducen en más kilos de producción. Esta relación es la que vamos a modelar con la ecuación que presenté antes:

$$y_s = \beta_s x_s \left(1 + \frac{\epsilon}{100}\right) . \tag{4.2}$$

Le agrego el subíndice s porque hacemos referencias a las semillas: la cantidad de producción en kilos y_s sigue una relación lineal con la cantidad de semillas plantadas x_s. Por supuesto, esta ecuación es desconocida en el mundo real, ésta es la estructura invisible que queremos descubrir usando nuestros conocimientos en ciencias de datos. A este escenario ideal vamos a darle un $\beta_s = 15$, es decir, por cada kilo de semillas sembradas, deberíamos obtener 15 kilos de producción. Como el mundo no sigue una línea recta perfecta, necesitamos agregarle ruido. Ahí es donde entra nuestro ϵ.

Este factor de ruido sigue una distribución normal $\mathcal{N}(10, 5^2)$, lo que significa que nos va a entregar un valor de entre 5 y 15 la mayor parte del tiempo, y entre 0 y 20 casi el 98% de

las veces (cosas de la distribución normal). Este ruido se divide para 100 y se suma uno porque lo que buscamos es tomar la relación lineal perfecta y provocarle una pequeña variación porcentual.

En otras palabras, nuestra producción va a seguir la relación: 15 kilos de producción por cada kilo sembrado, con un ruido aleatorio que hace que la producción varíe entre un 5% y un 10% extra la mayor parte del tiempo. Por ejemplo, sembramos 1 kg hoy, y en seis meses en lugar de producir 15 kg, obtenemos 15.75 kg, que es $15 + (15 \times 5\%)$; en otro terreno obtenemos 16.5 kg, que es $15 + (15 \times 10\%)$; y en el último conseguimos 15.15 kg, que es $15 + (15 \times 1\%)$. Puedes ver que cada elemento entre paréntesis representa el ruido aleatorio.

Así, obtenemos una variación realista que nos permite modelar esta producción agrícola en base a una relación lineal. Para que puedas digerirlo, te presento una gráfica donde mostramos la cantidad de semillas plantadas vs la producción, todo en kilos, considerando 100 plantaciones diferentes (figura 4.1). Puedes observar que los kilos producidos no son una línea recta, a veces hay más, a veces hay menos, como todo en la vida.

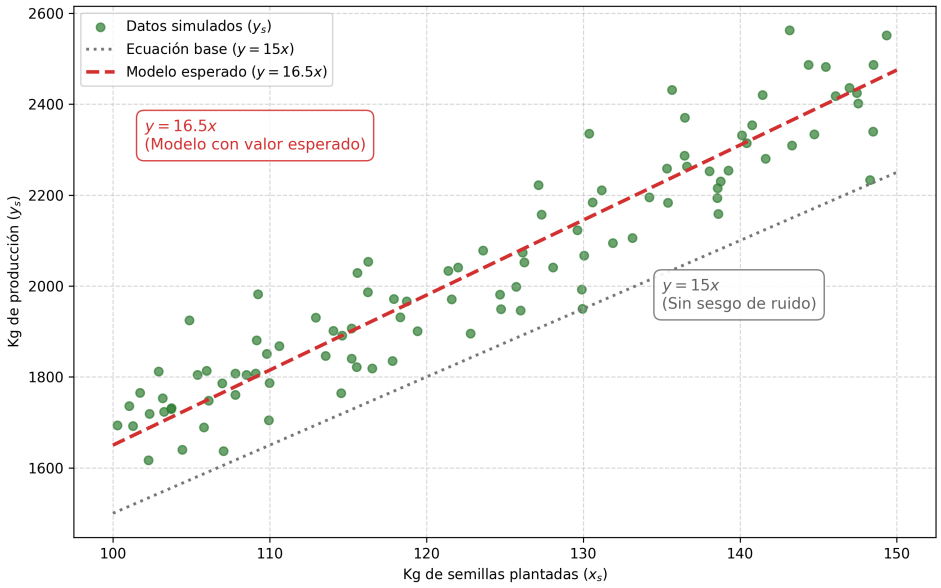


Figure 4.1: Simulación de 100 plantaciones: kilos producidos vs kilos plantados.

Cada punto en la figura 4.1 representa un terreno diferente donde se plantaron x_s kg de semillas. También agregué una línea que representa nuestra relación perfecta de 15 kilos producidos por cada kilo plantado. Y finalmente agregué un modelo ajustado donde se sumó el valor esperado a los 15 kg iniciales ($\hat{y}_s = (15 + 1.5)x_s = 16.5x_s$). Este modelo ajustado representa el mejor modelo que podríamos obtener conociendo todo lo que se puede conocer sobre la realidad que estamos modelando. Nos servirá de referencia cuando entrenemos nuestra regresión lineal, pero por ahora podemos ignorarlo, pues esta información es desconocida en el mundo real.

Ahora vamos a una simulación de producción. Controlamos una cantidad n de hectáreas donde cada una permite sembrar una cantidad variable de semillas. El objetivo de estas variaciones es que los modelos tengan múltiples opciones para inferir la regla general. Finalmente, estos terrenos sólo se pueden cultivar cada 6 meses, así que tampoco es que contamos con una cantidad ilimitada de datos. Vamos a simular 10 años de producción para 100 hectáreas mantiendo estable el comportamiento de los terrenos (no se deterioran). Y esto nos da un total de 2000 registros (100×20) para entrenar nuestros modelos.

Luego, hacemos un típico proceso de producción donde separamos el 80% de los datos para entrenamiento y el 20% restante para métricas de error. En estas condiciones, podemos evaluar los modelos a través de un gráfico muy ilustrativo. La figura 4.2 muestra una comparativa entre las predicciones de los modelos y los valores reales en el conjunto de pruebas. La línea roja representa una relación perfecta donde los puntos por encima indican que el modelo predijo un valor superior al real y los puntos por debajo que el modelo predijo un valor inferior.

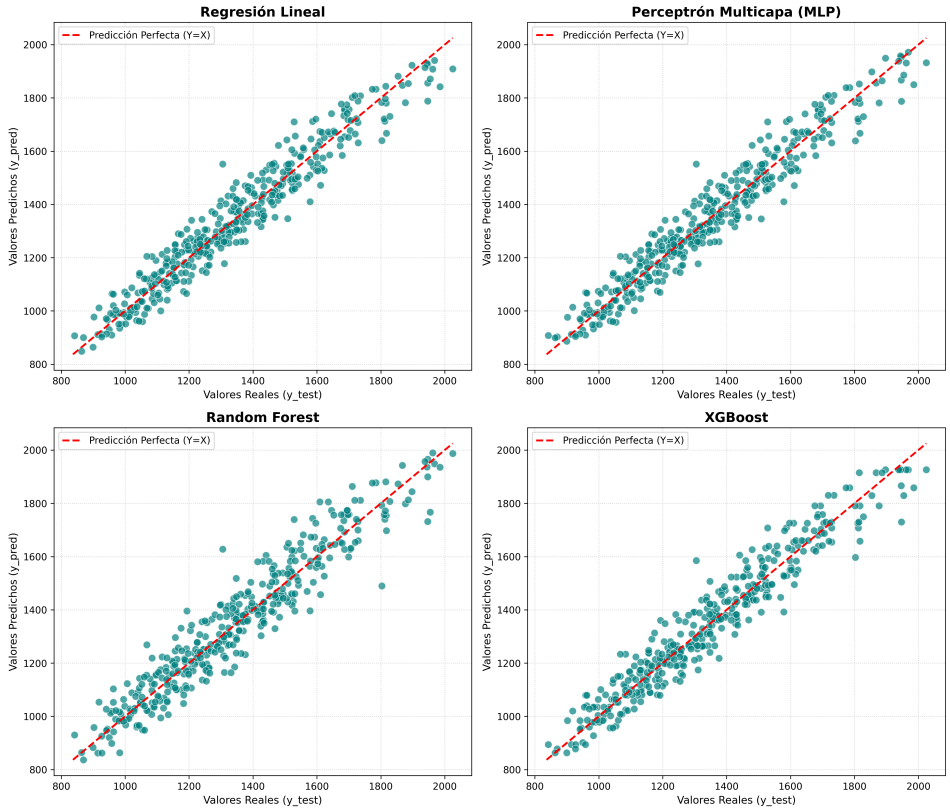


Figure 4.2: Comparación entre el valor predicho (eje y) y el valor real (eje x) para todos los modelos utilizados.

A primera vista, no hay una gran diferencia entre los modelos. Los puntos del random forest se ven algo más dispersos, pero resulta difícil confiar sólo en nuestro ojo. Necesitamos recurrir a

algo más concreto. Sin embargo, antes de avanzar quiero destacar los valores que presentan los ejes del gráfico, la producción de nuestros terrenos se encuentra entre los 800 kg y los 2000 kg, lo que implica que una diferencia inferior a 100 kg se puede considerar ruido.

Y es ruido lo que encontramos al medir los índices de error. Los resultados de las métricas más típicas se encuentran en la tabla 4.1. El RMSE y el MAE están en kilos, y ninguna diferencia entre los modelos supera al menos los 100 kg. A pesar de que el modelo lineal y la red neuronal obtuvieron mejores resulados que los bosques aleatorios, la diferencia sigue siendo muy pequeña. Con esto parece claro que no vale la pena elegir otra cosa que no sea un modelo lineal de toda la vida.

Table 4.1: Comparativa de rendimiento en el test set

Modelo	RMSE	MAE	R^2 Score
Regresión Lineal	63.1500	50.5687	0.9371
Perceptrón Multicapa (MLP)	63.1714	50.5960	0.9370
Random Forest	79.1799	62.8786	0.9011
XGBoost	66.4085	52.7134	0.9304

Probemos otro punto de vista. Voy a llenar cada modelo con una línea de puntos para ver cómo se comporta. El gráfico de la figura 4.3 muestra que la red neuronal se esfuerza por comportarse como una regresión lineal, mientras que el árbol aleatorio tiene varios puntos de quiebre y su inestabilidad no representa nada valioso porque el ruido que se produce alrededor de la línea recta es aleatorio y no se puede predecir.

Para finalizar esta sección, veamos cómo luce la ecuación deducida por la máquina para compararla con nuestra realidad oculta: $\hat{y}_s = 16.46x_s + 3.01$. Como puedes ver, esta aproximación es muy cercana a nuestro modelo de conocimiento completo: $\hat{y}_s = 16.5x_s$. Si existiera una relación lineal en el fondo de nuestros datos, en principio, no hay nada mejor para modelarla que una regresión lineal simple. Los modelos más complejos como random forest (o XGBoost) tratan de modelar el ruido, lo cual es imposible y la red neuronal se comporta como una regresión lineal, pero sin su interpretabilidad (es una caja negra). Ahora agreguemos algo de caos al asunto.

4.3 Cuando la crisis toca a tu puerta

Lo más interesante no es analizar qué pasa en las condiciones ideales, sino qué pasa cuando inyectamos algo de caos y destrucción. Por lo tanto, veamos qué pasa cuando el 10% de nuestros ciclos de producción sufren una catástrofe. ¿Por qué el 10%? Es un número arbitrario, pero bajo. Si fuera más alto seguramente implicaría una imprevisibilidad demasiado incómoda para

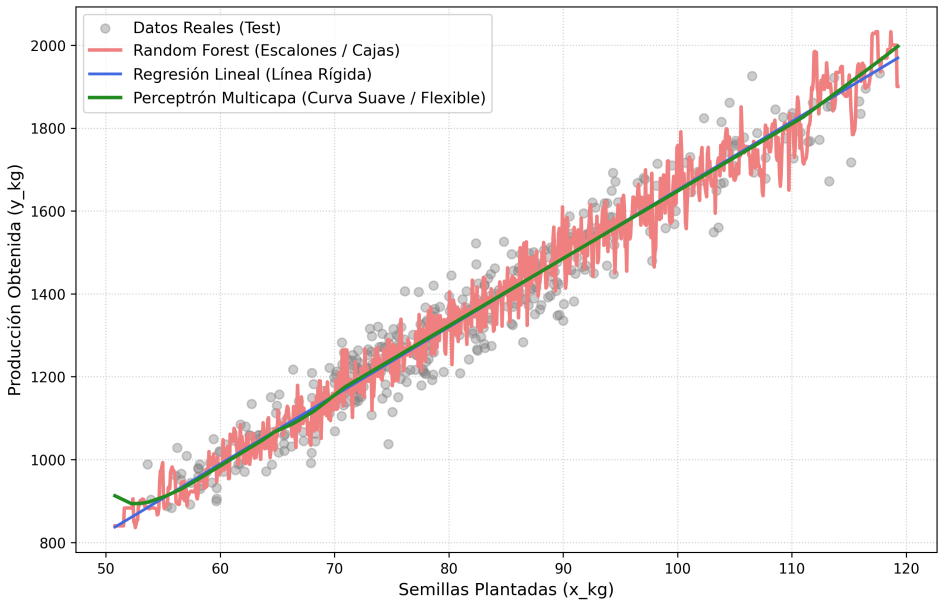


Figure 4.3: Comparación del comportamiento de los modelos sobre una línea de puntos de entrada.

mantenerse en el negocio. No. Nuestra producción es predecible la mayor parte del tiempo, pero nadie puede saberlo todo.

El 10% de las veces, en lugar de tener una correspondencia lineal, vamos a tener enormes caídas. Para ser preciso, voy a colocar una ruleta que va de 0 a 50, esta ruleta determina el porcentaje de la producción final. Es decir, si en un ciclo normal hubiésemos producido 1500 kg, sólo vamos a producir el porcentaje que arroje la ruleta, por ejemplo 20%, así que en una catástrofe, ese 1500 se convierte en $1500 \cdot 20\% = 300$. Estas catástrofes agregan ruido en nuestros datos, con lo que vamos a tener que lidiar.

La figura 4.4 muestra los nuevos datos. Como puedes observar, las cruces rojas representan momentos en los que la producción sufrió un accidente desastroso. Este accidente puede representar plagas, tempestades, algunas condiciones del suelo, lo que sea. Ahora estos datos forman parte de nuestro dataset y vamos a tener que tomar una decisión importante: ¿los usamos dentro del entrenamiento o no?

Primero, adoptemos la elección más ingenua. Esto puede parecer tonto para alguien con experiencia, pero un principiante puede creer perfectamente que vale la pena pasarle todos los datos a un modelo, porque representan información que el modelo va a poder interpretar y dar un resultado mejor. Sobre todo cuando uno no entiende la naturaleza de modelos complejos como una red neuronal. Parece que estas redes hacen magia, así que mejor pasémosle todo.

La siguiente opción es eliminar estos puntos extremos porque sabemos que son ruido sin

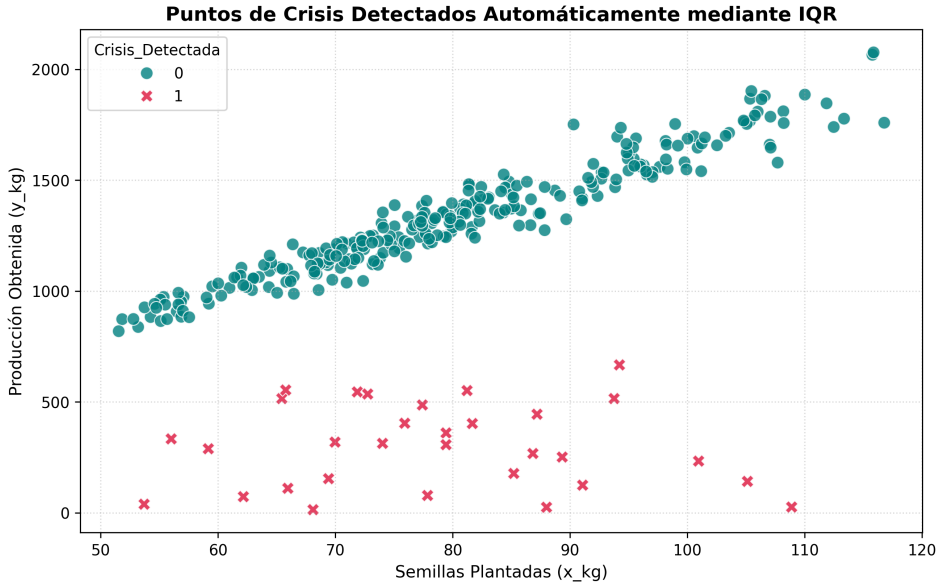


Figure 4.4: Nuestra producción ahora presenta crisis ocasionales.

significado que podamos interpretar. No hay información en ellos sobre la relación que existe entre semillas plantadas y producción obtenida, son resultado del azar inevitable de la vida. En este caso, para eliminar los puntos voy a usar la técnica IQR, lo que hacemos es tomar el rango intercuartil y lo usamos para definir un límite inferior. Todo lo que esté debajo del límite $= Q_1 - 1.5 \cdot \text{IQR}$ se considera un outlier que debemos eliminar. Ahora vamos a ver una comparación entre los modelos entrenados con ruido (conservando los valores extremos) y sin ruido.

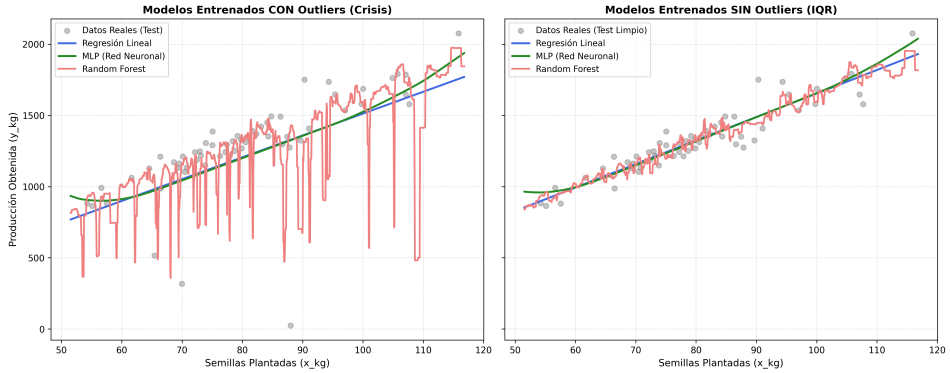


Figure 4.5: Comparación del comportamiento de los modelos cuando se entrenan con outliers y sin outliers.

La figura 4.5 contiene el comportamiento de los modelos entrenados con outliers a la izquierda

y los modelos entrenados con datos limpios a la derecha. Se observa que el ruido perjudica especialmente al bosque aleatorio. Ya que un bosque trata de fragmentar el espacio para agrupar los puntos, los outliers hacen que haya segmentos donde el bosque predice valores extremadamente bajos. Recordemos que estas caídas de producción no se pueden predecir, así que usar un modelo que predice valores tan bajos para una cantidad x de semillas implica jugar con fuego.

Otra consecuencia de usar outliers es que las rectas generadas por la regresión lineal y la red neuronal tienen una pendiente menos pronunciada y un corte en el eje y más bajo. Sus algoritmos de optimización tratan de minimizar la distancia que existe entre la predicción y el valor real, así que bajan todas las predicciones para poder acercarse a los valores extremos. Por lo tanto, usar outliers en el entrenamiento perjudica todas las predicciones a cambio de nada. La dificultad está en entender qué es ruido y qué sí contiene información valiosa. Para llegar a ese nivel de entendimiento, necesitamos conocer la naturaleza de los datos que estamos analizando. Los dueños del negocio, o algunos expertos en la industria, te pueden dar una mano acerca de qué no es normal. También existen análisis de anomalías automáticos, pero no vamos a entrar en ello, lo que nos interesa es que no importa qué tan complejo sea el modelo, agregar más datos *por si acaso* no es una buena idea.

Ahora, vamos a empujar esto un poco más. Supongamos que, como hoy está de moda hacer todo con un agente LLM, como Claude o Chat GPT, alguien le dice: tengo este dataset, entrenemos una regresión lineal y pongamos el modelo en producción. Entonces el LLM toma todos los datos, con todo y outliers, y coloca el modelo en producción. Lo que puede pasar cuando involucramos decisiones de negocio quizá te sorprenda, a mí me sorprendió, pues un modelo sucio puede superar a uno limpio en ciertas condiciones.

Establezcamos cómo funciona el negocio. Tenemos nuestra producción agrícola que maneja unos cientos de kilos cada ciclo. La manera de vender nuestra producción es a través de contratos que prometen una cantidad fija por adelantado. Los contratos sólo aceptan cientos de kilos cerrados. Entonces es imposible prometer 102 kg, sólo podemos prometer entregar 100 kg. También, vamos a vender a 10 dólares el kilo en el contrato, y sale más rentable esto que vender a último minuto (para empezar, que sea un 65% del valor del kilo en un contrato, es decir: \$6.50), digamos que estamos presionados porque el producto se arruina con facilidad. Por otro lado, si prometemos $\widehat{y}_s$ kilos en el contrato, y no cumplimos, pagamos una multa equivalente al valor que hubiéramos recibido por esa cantidad incumplida. Por ejemplo, si nos faltó 30 kg, y el contrato está a \$10 el kilo, debemos pagar \$300 por nuestro incumplimiento.

Finalmente, el cómo tomamos la decisión de cuánto comprometer en el contrato es que vemos la predicción del modelo lineal y redondeamos el valor hacia abajo. Por ejemplo, si el modelo dice que vamos a producir 125 kg, vamos a prometer 100 kg para el contrato, si hay un excedente, lo vamos a vender a último minuto (mercado spot) con un valor inferior. Si el modelo predice 1578 kg, prometemos 1500 kg, redondeamos hacia abajo, muy simple. Veamos los resultados.

Table 4.2: Comparativa económica: Regresión Lineal (Con Outliers vs. Sin Outliers)

Concepto / Métrica	Con Outliers	Sin Outliers	Diferencia (Δ)
Métricas de Volumen			
Volumen Contratado	36,000.0 kg	39,600.0 kg	+3,600.0 kg
Déficit Total (Faltante)	4,842.8 kg	5,731.0 kg	+888.2 kg
Excedente Total (Sobrante)	3,826.6 kg	1,114.9 kg	-2,711.7 kg
Flujos Monetarios ($)			
(+) Ingreso por Contratos	$311,572.35	$338,689.57	+$27,117.22
(+) Ingreso Venta Spot	$24,872.88	$7,246.68	-$17,626.20
(-) Pago Total en Multas	$48,427.65	$57,310.43	+$8,882.78
(=) Ganancia Neta	**$288,017.58**	**$288,625.83**	**+$608.25**

Parámetros Base: Precio Contrato = $10.00/kg; Tasa de Multa = 1.00 × Precio Contrato ($10.00/kg); Precio Spot = 0.65 × Precio Contrato ($6.50/kg).

La ganancia neta, junto a otros datos del experimento, se encuentra en la tabla 4.2. El modelo limpio gana más dinero, pero la diferencia no es tan grande. Claro, $608.25 es más que un sueldo básico en Ecuador (2026), pero considerando que la ganancia de ambos modelos es de más de 288 mil, la diferencia puede ignorarse. ¿Entonces no importa tener el modelo sucio trabajando? Bueno, analicemos qué está pasando.

El modelo sucio estima unos valores más bajos para todos los valores de entrada. En la tabla puede verse que los kilos totales comprometidos para contrato son menos que en el modelo limpio. Sin importar qué valor ingresemos, el modelo siempre va a predecir un valor inferior, por lo tanto, se compromete menos y tiene menos ventas a mejor precio. Por otro lado, al ver el déficit, es decir, la cantidad de kilos que prometió y no cumplió, el modelo sucio también tiene una cantidad inferior. Lógico, si comprometes menos, cuando suceda un accidente vas a pagar una multa más pequeña. Y si vemos los flujos de dinero, el modelo limpio gana más dinero en contratos y paga más en multas, pero sigue estando mejor porque la diferencia entre el precio de contrato y la venta de emergencia (spot) hace que comprometerse con más producción en el contrato salga más rentable.

Ahora, ¿qué pasa si variamos los valores de venta spot y la multa? ¿Existe un escenario donde el modelo sucio gane más dinero? Pues claro. Para entender el asunto utilicé dos valores para

el precio de venta spot y una línea de puntos para la variación de la multa. Primero vendemos el sobrante al 50% del precio del valor de contrato y luego lo vendemos al 80%.

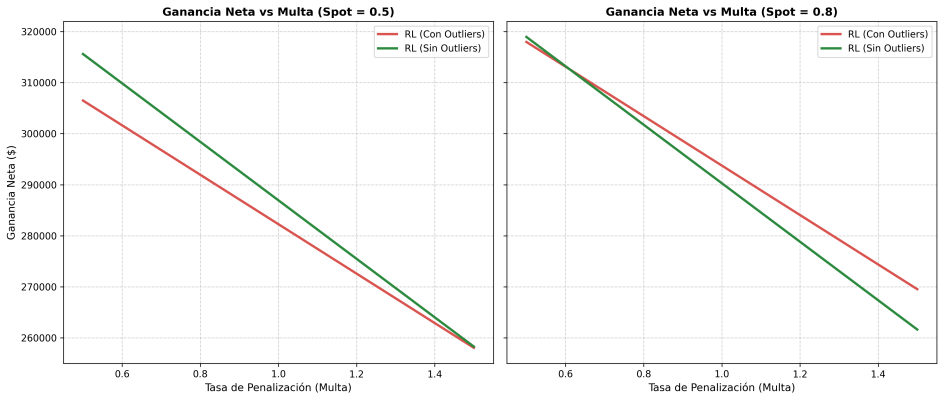


Figure 4.6: Comparación de la ganancia neta de un modelo sin outliers vs con outliers en diferentes condiciones de mercado.

La figura 4.6 muestra estos dos escenarios uno al lado del otro. El el eje x representa el valor de la multa, lo hago variar desde el 50% de valor del contrato hasta un 150%. Tengo entendido que estas multas son posibles en industrias donde un retraso al entregar la materia prima conlleva una catástrofe en toda la línea de producción. El cliente es muy sensible a los retrasos. La línea roja representa el modelo sucio y la línea verde el modelo limpio. Mientras la línea verde esté por encima de la roja, podemos decir que el modelo limpio resulta más rentable.

Como puedes ver, el valor de la multa y el precio de venta spot tienen un peso muy importante a la hora de evaluar los resultados de los modelos. Si somos capaces de vender el producto a última hora a un 80% de su valor (gráfico derecho), tomar un modelo con outliers nos ayuda, qué absurdo, ¿por qué pasa esto? Porque el modelo con outliers baja de manera sistemática sus predicciones, así que se reduce el incumplimiento de contratos e incrementa el producto disponible para venta spot. Es más importante reducir el valor pagado en la multa, así que un modelo más conservador se lleva la victoria.

Con esto, resulta fácil imaginar que alguien puede implementar un modelo base, completamente ciego a los datos, sin mayor análisis, y tener un buen negocio, porque la suerte hace que ese modelo conservador obtenga mejores resultados que uno que usa datos limpios. Sin embargo, si las cosas cambian, por ejemplo, si el valor de venta a última hora se reduce al 50% (gráfico izquierdo), entonces el modelo limpio siempre derrota al modelo conservador. Recordemos que el modelo conservador deja mucho producto fuera de los contratos que necesita venderse con rapidez. Además, en este caso sólo tenemos outliers hacia abajo, pero si hubiera outliers hacia arriba, una regresión lineal seguro colapsaría.

Con este análisis cerramos el capítulo. Quería introducir unos pocos pasos más allá de la comparación de modelos para difundir un estilo de pensamiento que aprendí del maestro Taleb.

Es más importante analizar las consecuencias de las decisiones que tomamos en base a las predicciones que hacemos. Queremos obtener lo que anhelamos, no tener la razón.

Me despido de este capítulo dejando otras preguntas interesantes que podrías investigar: ¿Qué técnica podríamos aplicar para tener una posición conservadora en un modelo limpio? ¿Qué pasa si no tenemos tantos registros o si cambia el comportamiento del suelo? (Con menos datos la red neuronal deja de funcionar). ¿Y cómo podríamos usar los outliers para beneficio de nuestro negocio?