# Modelar el mundo

**Analizando las consecuencias de lo inesperado, aleatorio y desconocido.**

Daniel DB

2026-09-06

# Table of contents

**Prefacio** **3**
Hoja de ruta . . . . . 3
Apoyar este proyecto . . . . . 3
Disclaimer sobre el uso de inteligencia artificial . . . . . 3

**1 Introducción** **4**

**2 Simulaciones** **6**

**I Simple vs complejo** **11**

**3 El promedio** **12**
3.1 Cuando el promedio es el héroe . . . . . 13
3.2 Cuando el promedio es el villano . . . . . 18

# Prefacio

Esta es la versión web de mi libro: Modelar el mundo. Se trata de un libro técnico donde se utilizan simulaciones hechas en python para explorar el funcionamiento de modelos de machine learning considerando la aleatoriedad.

## Hoja de ruta

| Capítulo | Título | Estado |
|---|---|---|
| **Capítulo 1** | Introducción | **Publicado** |
| **Capítulo 2** | Simulaciones | **Publicado** |
| **Capítulo 3** | El promedio | **Publicado** |
| **Capítulo 4** | Relaciones lineales | *En redacción (Octubre 2026)* |
| **Capítulo 5** | Relaciones no lineales | *Simulación terminada* |
| **Capítulo 6** | Encontrar la simpleza | *Diseño conceptual* |
| **Capítulo 7** | Complejidad justificada | *Diseño conceptual* |
| **Por definir** | Irreducibilidad computacional | *Simulación terminada* |

## Apoyar este proyecto

Si quieres apoyar este proyecto, puedes comprar la versión PDF del libro en Payhip. Descargar PDF en Payhip

## Disclaimer sobre el uso de inteligencia artificial

Este libro fue escrito por un humano (yo) al 100%. Los conceptos que se exploran son el resultado de mi razonamiento y curiosidad. El uso de inteligencia artificial se limita a la generación del código para las simulaciones. Específicamente, utilicé Gemini flash con pensamiento extendido.

# 1 Introducción

*Pavos esperando ser comidos*

Esta analogía la extraigo del maestro Nassim Taleb. El pavo tiene la teoría de que los humanos lo aman porque lo alimentan todos los días. El pavo científico se presenta ante el comité de pavos pensadores y muestra abundante evidencia que respalda su teoría de que la humanida está hecha para servir a los pavos: los humanos les dan alimento, casa y protección; por ello, el pavo científico consigue reconocimiento. Guía a la sociedad de pavos en base a sus predicciones y alienta a su pueblo con grandes sueños para el futuro. Entonces, llega el día de acción de gracias y todos los pavos pierden la cabeza.

El pavo no puede entender el día de gracias, está fuera de su alcance. De igual manera, resolver el problema de la inducción está fuera del alcance de la humanidad. No importa cuánta evidencia acumulemos en favor de una teoría, nuestra ignorancia de la totalidad nos puede colocar en una posición peligrosa si depositamos demasiada confianza en nuestras predicciones.

El mundo actual maneja modelos complejos que están lejos de ser entendidos. Creemos que esa complejidad nos ayuda a entender mejor el mundo. Falso. Si no somos capaces de entender cómo funcionan los modelos, mucho menos podemos entender el mundo que están modelando.

En mis primeros años de universidad veía el milagro de las redes neuronales y pensaba que las máquinas serían capaces de resolver la ecuación del universo. Sin embargo, mi apetito intelectual de matemática y filosofía me llevó a la conclusión de que eso es imposible.

Ya que hoy vemos anuncios sobre inteligencia artificial general y tenemos tanto dinero apostado en favor de esta tecnología (tenemos como humanidad aunque se trate de una minoría de millonarios locos), la imagen que yo tenía en mi época universitaria se está volviendo un meme del público general. Parece que estos modelos complejos serán capaces de resolver la ecuación del universo.

Mis apuestas están en contra. Esto se debe a que un estudio serio de lo que somos capaces de explicar demuestra que realmente conocemos muy poco. Y no importa cuánta información tengamos, eso no mejora nuestro entendimiento. A veces lo empeora.

Tal vez, una máquina que usa el lenguaje, como los actuales LLMs, sea capaz de reducir la complejidad en algunos sectores importantes, pero hay áreas que son indomables. El objetivo de este libro es explorar esas áreas y entender cuáles son las consecuencias de una exploración ingenua.

Ya que los datos son tan importantes en el mundo actual, y se acumulan de manera compulsiva, más vale alertar sobre el peligro de convertirse en un pavo. Creer que se sabe algo provoca la toma de riesgos agresivos innecesarios. Cuando uno se sabe ignorante evita envalentonarse demasiado. Si creemos que entendemos lo inentendible, perderemos la cabeza el día de acción de gracias.

# 2 Simulaciones

*La piedra filosofal*

Una simulación nos permite alejarnos de lo abstracto y tocar lo complejo. Esta herramienta es la columna vertebral del libro y por eso es importante empezar por aquí.

Usemos un ejemplo simple: lanzar una moneda.[1] Todos sabemos que existe una probabilidad $p = 0.5$ de obtener `cara` o `cruz` (ambas opciones son igualmente probables), y en este ejemplo `cara` cuenta como un éxito. Ahora, yo pregunto: ¿cuál es la cantidad máxima de éxitos seguidos que podemos obtener al realizar diez lanzamientos? Esto se puede resolver de forma analítica con multiplicaciones y potencias, pero ese camino no le interesa a nadie.

Lo más divertido que podemos hacer es programar una moneda y lanzarla. Hacemos diez lanzamientos para un experimento y repetimos el experimento mil veces. Con esto, vamos a tener una buena aproximación a la distribución de probabilidad de obtener $n$ éxitos seguidos.

Tenemos una moneda digital que obtiene `cara` o `cruz` con una probabilidad del 50%. Vamos a realizar 10 lanzamientos como podemos ver en la figura 2.1, y luego hacemos este mismo proceso durante mil experimentos para contar cuántos éxitos seguidos obtuvimos (figura 2.2). Finalmente, vamos a ver la distribución de esas rachas para ver el máximo de éxitos seguidos que podemos esperar si lanzamos una moneda 10 veces.




Figure 2.1: Lanzar una moneda 10 veces

El resultado es que después de mil experimentos vamos a poder contar cuántas veces aparecieron $n$ éxitos seguidos, dividirlo entre mil y tener una probabilidad aproximada:

[1] Esto puede parecer mucho, pero antes de lanzar tu hamburguesería considera que tener un par de empleados, la renta del local, y otros improvistos que incluyen impuestos, seguros y gastos sorpresa; reduce tu ganancia personal a unos $800 si tienes suerte.

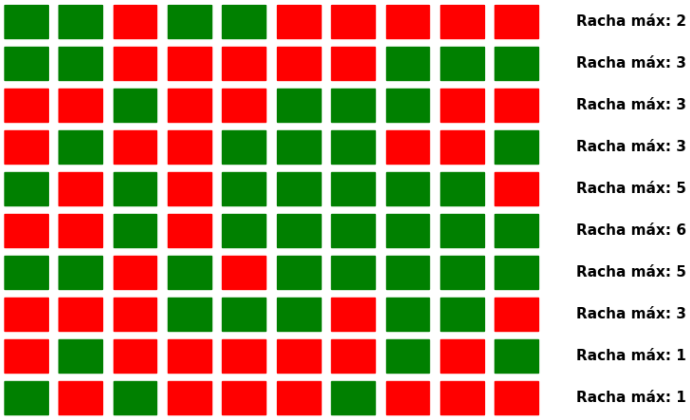



Figure 2.2: Repetición del experimento para contar la racha máxima

$$\hat{P}(\text{racha de } n) = \frac{f(n)}{1000}\,,$$

donde $\hat{P}$ es la probabilidad aproximada de obtener $n$ éxitos seguidos, y $f(n)$ es la frecuencia de nuestras rachas (cuántas veces apareció esa racha en los experimentos).

Antes de mostrarte las probabilidades me gustaría preguntarte qué tan probable crees que es obtener sólo éxitos en 10 lanzamientos. Dame un número del 1 al 100. Espero que lo tengas en mente cuando te revele la verdad. En la figura 2.3 puedes ver el resultado de la simulación. La probabilidad de obtener `cara` más de 5 veces seguidas se vuelve casi imposible, menos del 5%. Lo más probable es obtener 2 y 3 éxitos seguidos, hasta 4 resulta razonable, pero más allá de esos valores, estamos en el mundo de la fantasía.

Hay un acertijo que pregunta ¿cuál es la probabilidad de obtener `cara` si ya lanzamos una moneda 10 veces y todas salieron `cara`?, y la gente se siente tentada a decir que lo más probable es que salga `cruz`, para estabilizar la cuenta. Con una moneda normal, sabemos que la probabilidad se mantiene en 50%, porque cada lanzamiento es independiente. No importa si ya obtuviste `cara` 10 o 100 veces, la moneda no lleva la cuenta. Sin embargo, con lo poco probable que es obtener 10 éxitos consecutivos, podemos empezar a dudar de que se trate de una moneda normal. Se vuelve viable que se trate de una moneda cargada.

Aunque el acertijo se haga para un entorno teórico perfecto, nosotros no vivimos en un mundo teórico perfecto. Si una moneda se lanza 10 veces y sale `cara` 10 veces, ahí hay truco. De hecho, podemos hacer una nueva simulación con monedas cargadas para ver qué tan probable es obtener 10 éxitos seguidos si tenemos una moneda que salta a nuestro favor.

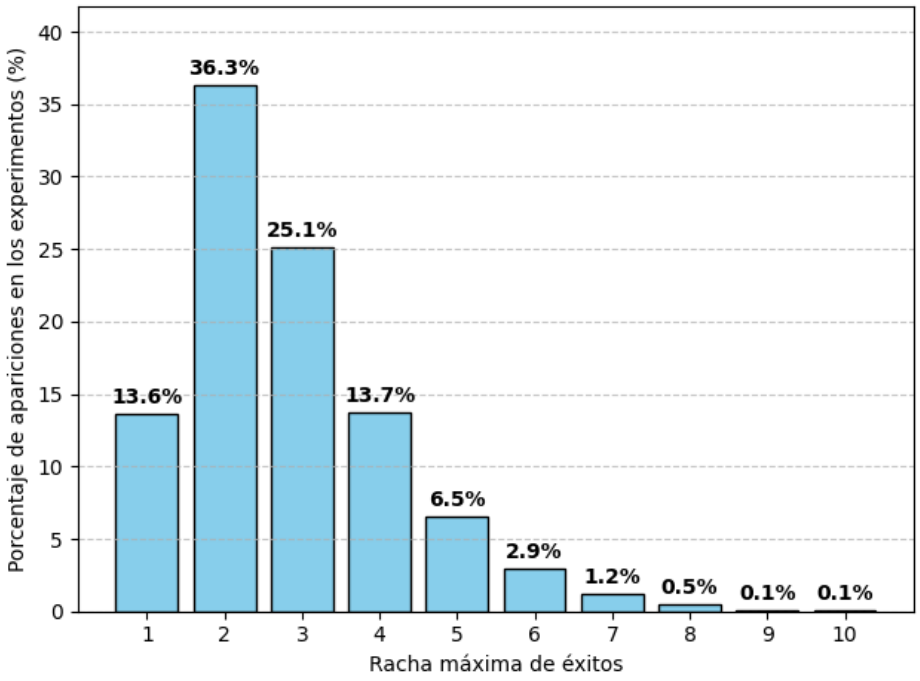



Figure 2.3: ¿Cuántos éxitos seguidos puedo conseguir si lanzo una moneda 10 veces?

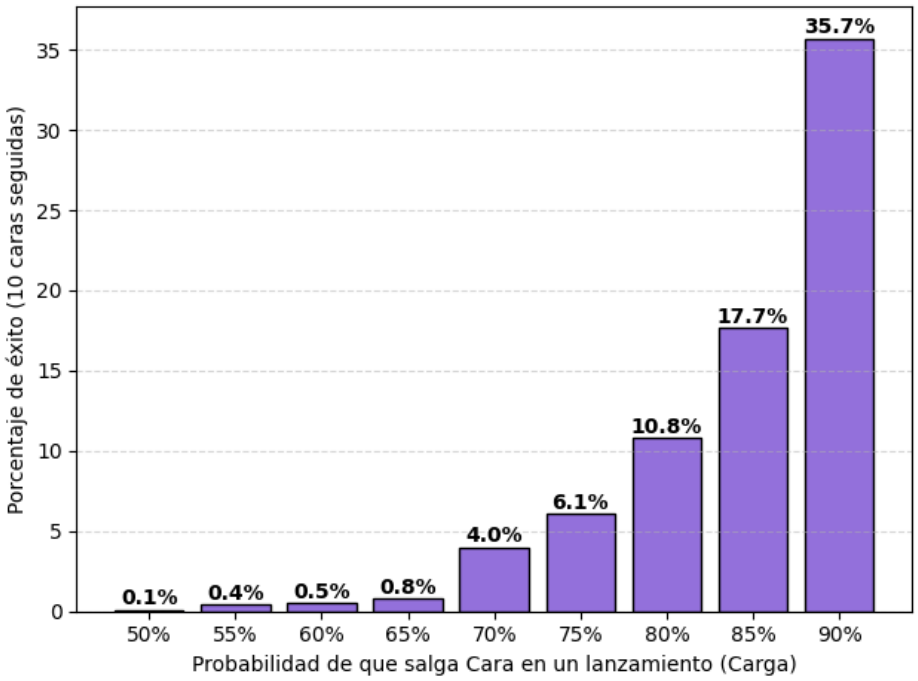



Figure 2.4: ¿Qué tan probable es obtener 10 éxitos consecutivos con monedas cargadas?

Los resultados están en la figura 2.4. Observa que incluso con una carga del 90% ($p_{\text{cara}} = 0.9$), obtener 10 éxitos consecutivos apenas alcanza la probabilidad del 35%. Por lo que si alguien te pregunta qué es más probable, que salga `cara` o `cruz`, después de que salió cara 10 veces seguidas, puedes decir con mucha confianza que lo más probable es que salga `cara`, porque la moneda debe estar cargada para obtener esos resultados.

De esta manera cerramos el capítulo, hemos observado el poder de las simulaciones, y también he establecido mi intención con este libro: hay que analizar los problemas más allá del escenario teórico que no se presenta nunca. Si el acertijo de arriba fuera una apuesta con sumas importantes de dinero, el teórico que se pasa de listo diciendo que la moneda no lleva la cuenta iría a la quiebra. Nuestra intuición nos dice que algo anda mal con obtener 10 éxitos seguidos, hay que escucharla. Sobrevivir es más importante que tener la razón.

Para finalizar, quiero agregar que otra ventaja de hacer simulaciones es que nos permite construir un entorno de conocimiento completo, donde sabemos todo lo que se puede saber sobre él, a diferencia de lo que pasa en el mundo real. Entonces, como conocemos la respuesta verdadera que oculta la aleatoriedad, podemos comparar el resultado de los modelos con la realidad más exacta. Lo cual no ocurriría si usáramos datasets abiertos de internet, porque no conocemos la distribución que sigue el mundo y cualquier estimación que hagamos puede meternos en el problema del pavo. No importa qué índice de error usemos para medir los resultados de un modelo, sólo contamos con lo que hemos observado. Por otro lado, una simulación nos ofrece algo sólido para medir nuestros modelos y ver cuáles sobreviven. Y ya que la vida no nos permite ver sus secretos, podemos asumir que un modelo que se comporta mal en una simulación va a ser peor en el mundo real.

# Part I

# Simple vs complejo

# 3 El promedio

*Ingenuidad y manipulación*

El promedio es la herramienta estadística más conocida, y también nos resulta la más natural, pues la usamos desde que entramos a la escuela. Nuestra experiencia con el promedio nos indica que puede usarse como resumen de un conjunto de datos, ya que si tienes un estudiante con un promedio de 9 sobre 10, concluyes que se trata de uno bueno sin necesidad de ver todo su historial.

Debido a esto, podemos llegar a malinterpretar lo que significa un promedio cuando se trabaja con datos que no muestran la estabilidad de las calificaciones escolares. Veamos un ejemplo de esta estabilidad. Si eras un chico que obtenía 8 en todas sus tareas y exámenes, un único 0 no causaba un colapso de tu nota final, como un 10 no te convertía en el mejor de la clase. Podemos verlo en este ejemplo:

$$\frac{8.5 + 8.25 + 7.75 + 9 + 7.5 + 8 + 8 + 8.5 + 7.75 + \mathbf{0}}{10} = \mathbf{7.33}\,,$$
$$\frac{8.5 + 8.25 + 7.75 + 9 + 7.5 + 8 + 8 + 8.5 + 7.75 + \mathbf{10}}{10} = \mathbf{8.33}\,.$$

Ir de un extremo al otro equivale a un punto de diferencia, lo cual puede parecer mucho cuando eres un niño que intenta impresionar a sus padres, pero en términos prácticos, se trata de ruido.

Las cosas cambian cuando hablamos de dinero, un tema que le interesa a todo el mundo. Ya que la distribución del dinero muestra enormes desigualdades, usar esta métrica es una estrategia de manipulación común para venderte sueños imposibles.

Un ejemplo clásico es este anuncio que me aparece en cada rincón de internet: obtén un sobresueldo de $x$ dinero haciendo trading, o comprando esto, o vendiendo aquello. Cuando vas a los detalles te advierten que esos valores son el promedio obtenido de un grupo de pobres diablos que intentaron el mismo método inútil que quieren venderte. Veamos por qué se trata de una mentira.

Puedes tener a noventa y nueve personas con una ganancia anual nula y a una única persona con un aporte gigante de un millón:

$$\frac{99 \times 0 + 1\,000\,000}{100} = 10\,000\,.$$

Luego, podrías escuchar que el método te consigue una ganancia anual promedio de unos fabulosos \$10 000. Y concluyes (erróneamente) que lo mejor que puedes hacer es adquirir el curso que te están vendiendo.

Por eso, mi intención con este capítulo es abrirte los ojos ante la amenaza de darle demasiada importancia a un promedio si no conoces la naturaleza de la variable que estás analizando. No es lo mismo hablar de un promedio limitado por el mundo físico, que de uno que trabaja sobre sistemas de información.

## 3.1 Cuando el promedio es el héroe

Pongamos un ejemplo donde el promedio tiene sentido: queremos estimar el consumo medio diario de gramos de carne en un local de hamburguesas del barrio. Esto nos permite planificar gastos, y en este escenario tiene todo el sentido del mundo usar un promedio como estimador porque nunca vas a tener cien clientes que consuman una hamburguesa junto a uno que consuma mil.

Es posible que la estimación tenga pequeñas explosiones inesperadas (como tener el restaurante lleno), pero sigue estando limitado por un sistema físico (el tamaño del restaurante). No puedes pasar de cero a un millón en un minuto.

En este sentido, lo único que hace falta es la desviación estándar. Ninguna media tiene sentido sin su varianza. Bajo una campana de Gauss perfecta, tienes alrededor de un 68% de la información dentro de una desviación estándar hacia arriba y hacia abajo.

Para entenderlo mejor, hagamos una simulación. La cantidad de gramos que contiene cada hamburguesa está estandarizada: una hamburguesa normal tiene 125 g, una premium tiene 200 g, y una hamburguesa doble tiene 250 g.

Luego asignamos probabilidades razonables para cada hamburguesa: la probabilidad de que un cliente compre una hamburgusea normal es $p_{\text{hnormal}} = 0.5$, la de que compre una premium es $p_{\text{hpremium}} = 0.3$, y para llegar a 1, la de una hamburguesa doble tiene que ser $p_{\text{hdoble}} = 0.2$.

Esto signficia que cuando un cliente se para frente al cajero, tiene una probabilidad $p_i$ de ordenar una de esas hamburguesas, donde $i \in \{\text{hnormal}, \text{hpremium}, \text{hdoble}\}$. Lo que se traduce en que la probabilidad de comprar una hamburguesa disminuye al incrementar el precio, algo que tiene todo el sentido del mundo.

Con estas probabilidades, utilizamos una distribución normal $\mathcal{N}(20, 5^2)$ para simular la entrada de clientes durante las 5 horas que el local está en funcionamiento. Esta distribución tiene una media de 20 con una desviación estándar de 5, y el local tiene una capacidad máxima de 30

clientes por hora. Esto significa que la mayor parte del tiempo, el local va a tener entre 15 y 25 clientes cada hora, pero si llega a tener más, nunca van a ser más que 30 (límites físicos).

Puedes entender esto gráficamente en la figura 3.1. La figura representa un único día de trabajo. La cantidad de clientes está relacionada con el consumo de carne, como es de esperarse, pero como la elección de los clientes también implica aleatoriedad, a veces puede haber menos clientes, pero más consumo de carne. En cualquier caso, podemos ver que el día inició con local lleno, tenemos 30 clientes, que es el máximo que puede haber cada hora. Luego, la cantidad de clientes baja, pero vemos que este día nunca llega a 10, lo cual resulta muy poco probable.

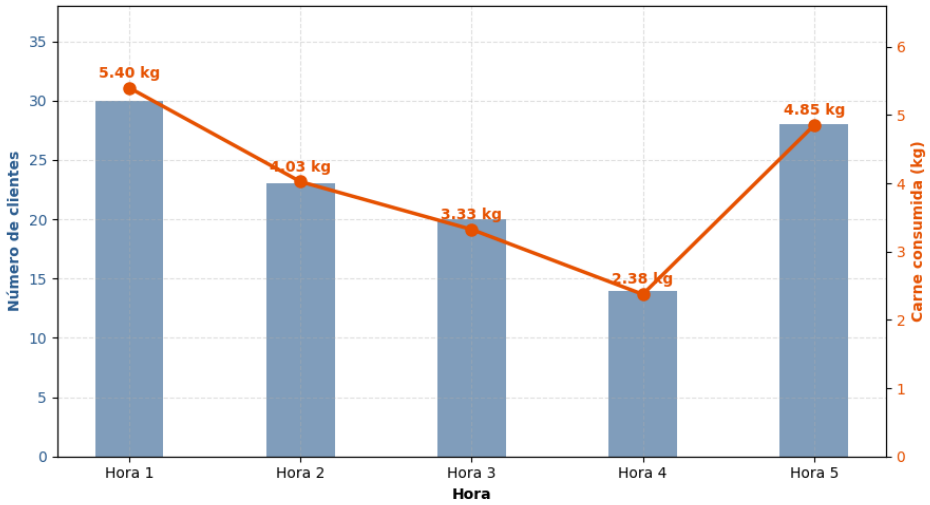



Figure 3.1: Simulación de un día de trabajo (5 horas).

Ahora podemos simular un mes y recopilar datos. Primero, tenemos un consumo diario individual:

$$C_d = \sum_{i=1}^{N} X_i \,,$$

donde $C_d$ es el consumo total de gramos de carne de un día, $N$ representa el número total de hamburguesas vendidas ese día, y $X_i$ representa los gramos que contiene cada hamburguesa vendida (que puede ser normal, premium o doble según su probabilidad). Así, obtenemos valores de 30 días para calcular un promedio de consumo diario con su desviación estándar:

$$\bar{C} = \frac{1}{30} \sum_{d=1}^{30} C_d \,,$$

$$s = \sqrt{\frac{1}{30} \sum_{d=1}^{30} (C_d - \bar{C})^2} \,.$$

Es decir, durante cinco iteraciones (cinco horas de funcionamiento), generamos clientes de forma aleatoria que van a elegir una hamburguesa según su probabilidad $p_i$, luego sumamos

los gramos de carne que contiene cada hamburguesa elegida a un total de consumo diario $C_d$, y repetimos este experimento 30 veces para obtener los valores de un mes. Finalmente, calculamos el promedio diario con su desviación estándar para decidir cuánta carne vamos a comprar.

El resultado de esta primera simulación es visible en la figura 3.2, tenemos el total de carne consumida en kilos cada día. Esos valores los dividimos para 30 y obtenemos un promedio de 16.52 kg, con una desviación estándar de 1.87 kg. Puedes observar que el promedio junto a sus desviaciones estándar para arriba y para abajo consiguen abrazar a la mayoría de los valores obtenidos durante ese mes. Hay unos pocos picos hacia arriba y hacia abajo, pero esas excepciones tampoco se alejan demasiado de lo esperado. Esto es lo bello de trabajar en entornos físicos limitados que siguen las leyes del universo.

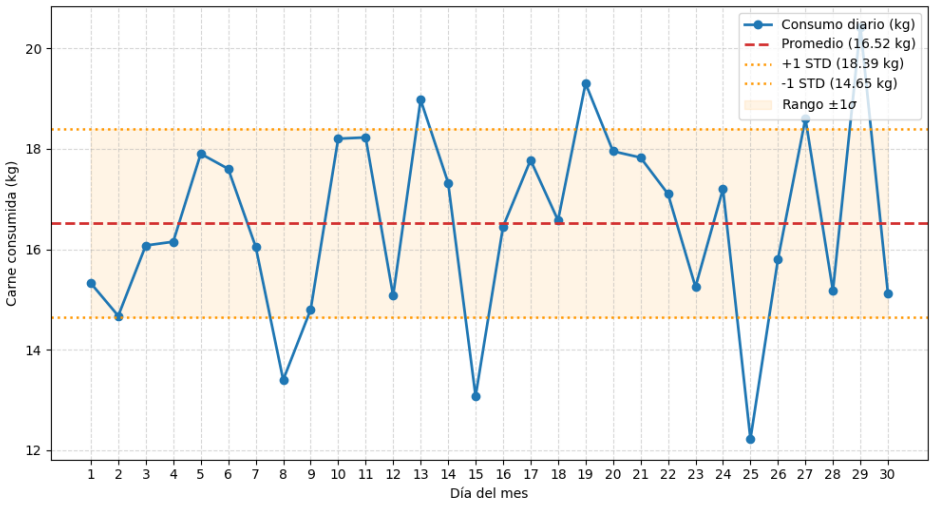



Figure 3.2: Simulación de un mes de trabajo.

Podemos imaginar estos datos como el monitoreo que hacemos de un local en el mundo real. Vemos cuántos clientes entran y cuántas hamburguesas se preparan durante un mes y obtenemos estos resultados: la media muestral es de 16.52 kg con una desviación estándar de 1.87 kg. Como la desviación es menor de 2 kg, creo que lo mejor es concentrarse en el promedio obtenido.

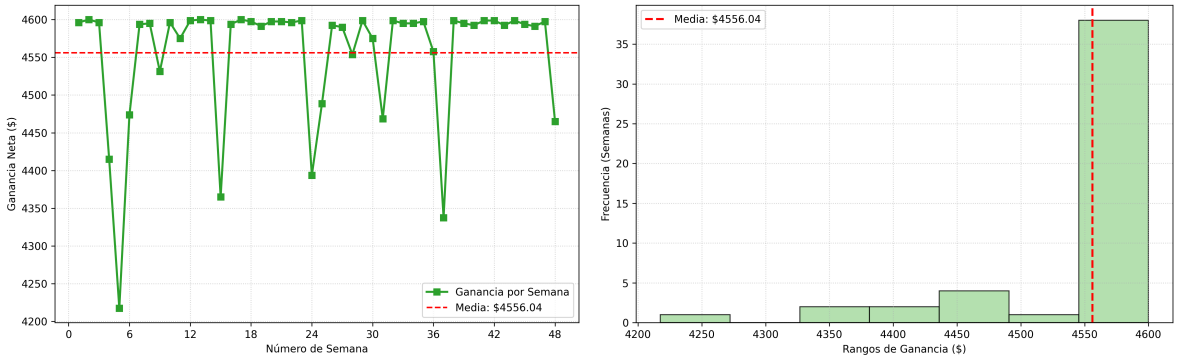
Ahora, debemos tomar una **decisión de negocio**: el resto del año vamos a comprar la carne de forma semanal, y vamos a comprar el valor promedio diario multiplicado por 7. Algo importate a tomar en cuenta es que en este mundo imaginario la carne sólo se vende por kilos enteros y cuesta $10 el kilo.

Entonces, tenemos que $16.52 \times 7 \approx 115$, por lo tanto, vamos a comprar 115 kg todas las semanas. Eso equivale a un gasto semanal de $1150. Finalmente, aplicamos la técnica del foodcost al 20% (los ingredientes representan el 20% del precio final del producto). Aunque sólo se venden kilos enteros, nosotros podemos estimar el valor de los gramos para nuestras

hamburguesas. Luego tomamos ese valor y lo multiplicamos por 5. Esto nos da como resultado que las hamburguesas van a costar:

$$
\begin{aligned}
1\ \text{kg} &= 1000\ \text{g}\,, \\
1\ \text{kg} &= 10\,\$\,, \\
1000\ \text{g} &= 10\,\$\,, \\
\text{precio_hnormal} &= \frac{125\ \text{g}}{1000\ \text{g}} \times 10\,\$ \times 5 = \mathbf{6.25}\,\$\,, \\
\text{precio_hpremium} &= \frac{200\ \text{g}}{1000\ \text{g}} \times 10\,\$ \times 5 = \mathbf{10.00}\,\$\,, \\
\text{precio_hdoble} &= 6.25\,\$ \times 2 = \mathbf{12.50}\,\$\,.
\end{aligned}
$$

Con estos precios, y estableciendo que el comportamiento de los clientes se va a mantener estable el resto del año, veamos qué tal le va a esta estrategia comercial. Vamos a analizar algunos puntos fundamentales para decidir si la estrategia funciona. ¿Estamos generando ganancias? Sin ganancias netas, nada tiene sentido. ¿Nos está sobrando carne? Porque si nos sobra mucha carne cada semana estamos comprando de más y desperdiciando recursos. Y finalmente, si no nos sobra, ¿se nos acaba rápido y nos obliga a cerrar el negocio? Tampoco resulta práctico comprar muy poco y fallarle a los clientes.




(a) Línea de tiempo de ganancias.

(b) Distribución de ganancias.

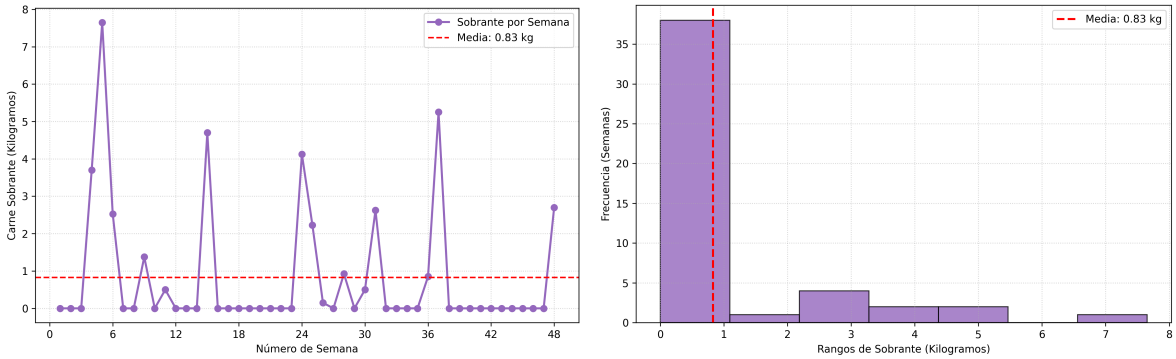
Figure 3.3: Ganancias netas durante un año de trabajo.

La figura 3.3 muestra las ganancias netas a lo largo del año y lo que tenemos es una ganancia constante que siempre supera los 4 mil dólares semanales.[1] Esto significa que usar el promedio como estimador por lo menos sí nos resulta rentable. No nos hizo falta analizar series de tiempo

[1]Esto puede parecer mucho, pero antes de lanzar tu hamburguesería considera que tener un par de empleados, la renta del local, y otros improvistos que incluyen impuestos, seguros y gastos sorpresa; reduce tu ganancia personal a unos $800 si tienes suerte.

ni aplicar estadística avanzada, un promedio centrado en factores físicos nos resultó confiable. También puedes ver que las ganancias ya no se comportan como una distribución normal. Tenemos un bloque altamente concentrado en la parte alta de las ganancias. Es decir, la mayor parte de las semanas la ganancia es superior al promedio de $\$4,523$, pero hay semanas donde la ganancia se cae. Veremos cómo nos afectan distribuciones asimétricas con valores extremos en más profundidad en el próximo escenario.

Ahora hay que analizar el consumo de carne. ¿Estamos comprando demasiado y podemos ahorrar unos dólares? La figura 3.4 nos muestra que la carne sobrante puede alcanzar algunos picos de 8 kilogramos, pero la mayor parte del tiempo, terminamos la semana sin nada. Esos pocos picos de sobras se pueden convertir en el almuerzo familiar o en una donación para los últimos clientes, la verdad es que no representan un problema considerando las ganancias.




(a) Línea de tiempo de la carne que sobra.

(b) Distribución de las sobras.

Figure 3.4: Cantidad de carne que sobra después de terminar la semana laboral.

Finalmente, la carne se nos acaba la mayor parte del tiempo, ¿pero tenemos suficiente para satisfacer a nuestros clientes todos los días? Primero hice un análisis de los datos generados para ver qué día de la semana se acababa la carne, todos los resultados dieron como respuesta el domingo. Así que podemos confiar en que la cantidad de carne que compramos es suficiente para cumplir con nuestra semana laboral. Si el domingo cerramos temprano por falta de ingredientes no podemos culparnos, el domingo es un día de relajación. La figura 3.5 nos muestra a qué hora suele terminarse la carne, podemos observar que sólo hubo un domingo en el que tuvimos que cerrar el local después de la primera hora. La mayor parte del tiempo la carne se termina en la hora 4 y 5, sobre todo en la 5. Es decir, las semanas que no nos sobra carne, podemos atender el local los domingos sin problema, si cerramos unos minutos antes, no pasa nada.

Con esto cerrramos nuestro primer escenario, ideal para el promedio. Ya que estamos tratando con variables limitadas por el mundo físico: carne que puede consumir un cliente y cantidad de clientes dentro del local, el promedio encuentra esa estabilidad que necesita para brillar. Ni siquiera tomamos en consideración las desviaciones estándar, usamos el modelo más simple posible. Y tal vez creas que se pueden mejorar las predicciones con un modelo más complejo,

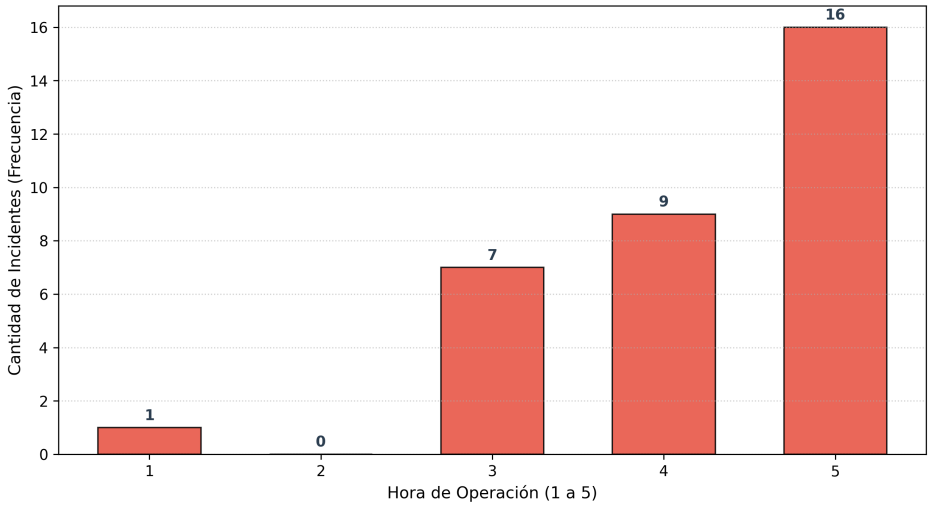



Figure 3.5: Hora a la que se termina la carne los domingos.

volveremos a esta cuestión más adelante, pero déjame adelantarte que no se puede. Por ahora, después de haber visto el promedio brillar, es momento de ver su caída.

## 3.2 Cuando el promedio es el villano

En nuestro siguiente escenario vamos a abandonar la seguridad del mundo físico y navegaremos los temibles y turbulentos mares de la información. Vamos a seguir con nuestro local de hamburguesas, para no romper la magia que creamos hace poco, y lo único que vamos a cambiar es el sistema para hacer los pedidos.

Queremos que nuestras hamburguesas nos den la libertad financiera, así que nos expandimos al mundo online para poder entregar pedidos hechos en aplicaciones de comida a domicilio. Igual que antes, queremos estimar cuánta carne debemos comprar cada semana. Igual que antes, hacemos un estudio preliminar del promedio de pedidos que se realizan en estas aplicaciones. La gran derrota es que no analizamos la distribución de esos pedidos.

El escenario está construido de esta manera. Las grandes cadenas de hamburguesas como McDonald's o Burguer King se llevan el 80% de los pedidos, mientras que los locales de barrio como el nuestro sólo se reparten el 20%. Esto es lo que se conoce como ley del 80/20. La competencia de barrio la dejé en 27 locales, parece un número razonable.

Luego, la cantidad de usuarios que hacen pedidos de hamburguesas por hora la modelé con una distribución normal $\mathcal{N}(150, 20^2)$, en general podemos esperar que haya entre 130 y 170 personas pidiendo hamburguesas cada hora. Sin embargo, la mayoría de esos usuarios (el 80%) va a realizar un pedido en una gran cadena. Esto significa que nosotros deberíamos pensar en

un promedio de $150 \times 0.2 = 30$ (¡repartidos entre 27 locales de barrio!), como un estimador sencillo, pero vamos a irnos por el lado ingenuo para demostrar que el promedio nos puede arruinar.

Dejemos correr la simulación y adoptemos el punto de vista del dueño de local ingenuo que mira una página de estadísticas de sitios web. Igual que en el escenario anterior, lo que queremos es un promedio diario para multiplicar por 7 y comprar la carne para la semana. Vemos una página de estadísticas web y nos enteramos de que se realizaron un promedio de 743 pedidos por día en el último mes. Con esa información lo que hacemos es dividir este número de pedidos para la cantidad de locales de hamburguesa que en hay la ciudad (incluyendo las grandes franquicias), y encontramos que debemos esperar unas 24 hamburguesas diarias ($743/30 = 24.77$).

Si esperamos 24 hamburguesas diarias, vamos a tener que comprar carne para llegar a 168 ($24 \times 7 = 168$). Digamos que en la aplicación sólo vamos a poner la hamburguesa normal, nada de premium ni doble, tenemos control sobre eso, y no queremos complicarnos la vida. Si nuestra hamburguesa normal tiene 125 g, entonces vamos a comprar 21 kg de carne cada semana ($125 \times 168 = 21\,000$). Ahora que hemos tomado nuestra decisión, veamos cómo nos va.

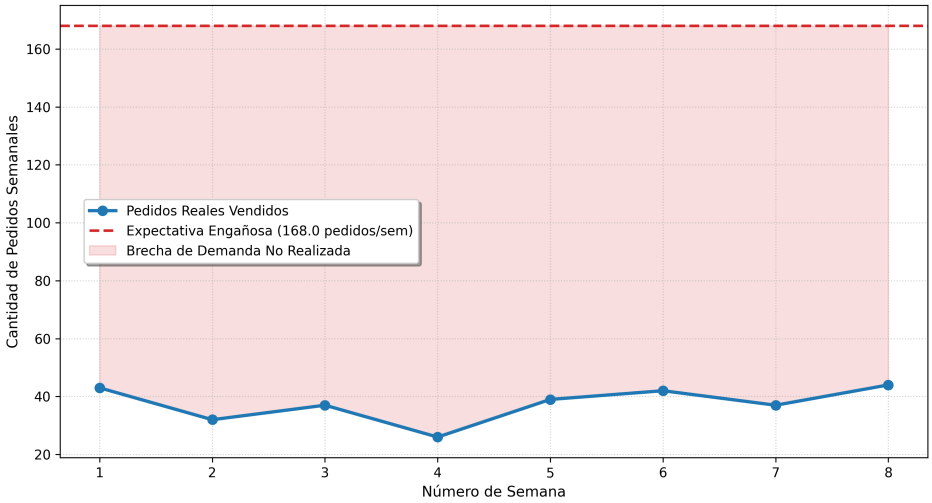
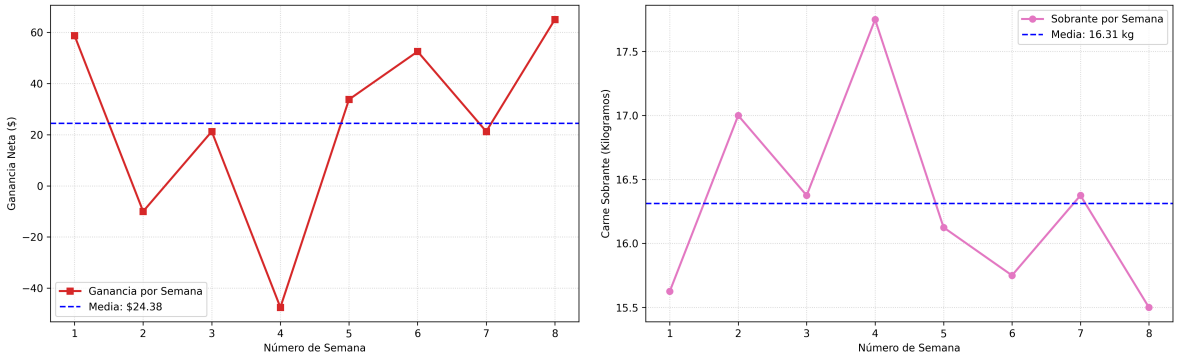



Figure 3.6: Diferencia entre nuestra expectativa y la realidad.

Nosotros esperábamos conseguir alrededor de 168 pedidos semanales, sin embargo, durante dos meses hemos visto cómo la realidad nos golpeaba semana a semana. Por ese motivo, detenemos el experimento y hacemos cuentas de los daños. La figura 3.6 nos muestra la diferencia entre nuestro estimador y los pedidos que conseguíamos en la aplicación. Nunca llegamos ni a la mitad de lo que habíamos estimado, lo cual, ya podemos deducir, se traduce en un desperdicio de comida y de dinero.

En la figura 3.7 podemos observar que nuestro estimador nos perjudicó de lo lindo. Por un




(a) Ganancias netas semanales.

(b) Kilos de carne sobrantes.

Figure 3.7: Resultados de nuestro estimador (promedio) ingenuo.

lado (figura 3.7a), vemos que nuestras ganancias no son constantes, de hecho, hay semanas en las que tenemos pérdidas considerables. Por el otro (figura 3.7b), tenemos más de 15 kg sobrantes cada semana. Con eso podemos hacer muchas hamburguesas y lo estamos tirando a la basura.

Curiosamente, cuando vemos el balance total de estos dos meses, tenemos una ganancia neta de $195.00. Esto es gracias a que el food cost al 20% es una estrategia que permite mantener un restaurante. Sin embargo, estos $195.00 extra (extra porque ya antendemos a nuestros clientes dentro del local con buenas ganancias) no justifican el desperdicio de comida. Además, existe la posibilidad de que hayamos tenido suerte, si el experimento seguía, íbamos a terminar con pérdidas.

¿Cómo hubiésemos podido evitar caer en esta trampa? Lo primero hubuiera sido entender la distribución de los datos. A diferencia de lo que pasaba en nuestro local de hamburguesas, los pedidos que se realizan en una aplicación no tienen limitaciones. Las grandes franquicias, debido a su popularidad, concentran la mayor parte de los pedidos, y no hay ningún límite físico o natural que evite que los usuarios soliciten todos sus pedidos a aquellas franquicias que les gustan, ignorando a todos los demás.

Como analistas, debemos ver cómo se reparten los datos más allá de un promedio diario. De haberlo hecho en este escenario, hubiéramos encontrado que, quitando las grandes franquicias, el resto de locales luchan por el 19.8% de los pedidos (figura 3.8).

Con esta información, como mínimo hubiéramos bajado nuestras expectativas. Como máximo, hubiéramos usado el promedio de pedidos repartido entre 28 locales ($27 + 1 = 28$ porque también consideraríamos el nuestro). Claro, antes de tomar esta decisión, hay que asegurarse de que no haya desigualdades entre estos 27 locales de barrio. La figura 3.9 nos muestra que, quitando las grandes franquicias, tenemos una distribución bastante uniforme donde algunos tienen un poco más, otros un poco menos, pero se ve cierta estabilidad en la cual podríamos confiar los primeros meses.

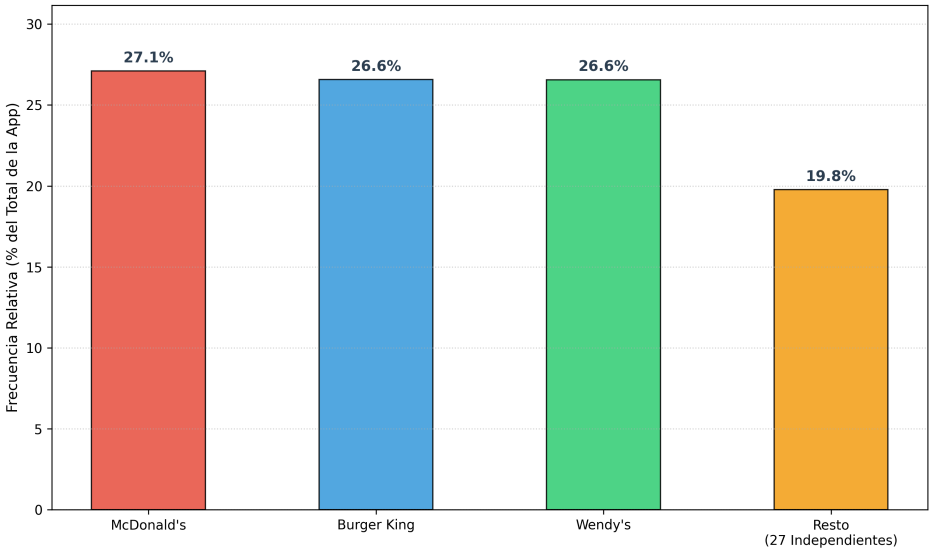



Figure 3.8: ¿Cómo se reparten los pedidos considerando las grandes franquicias?

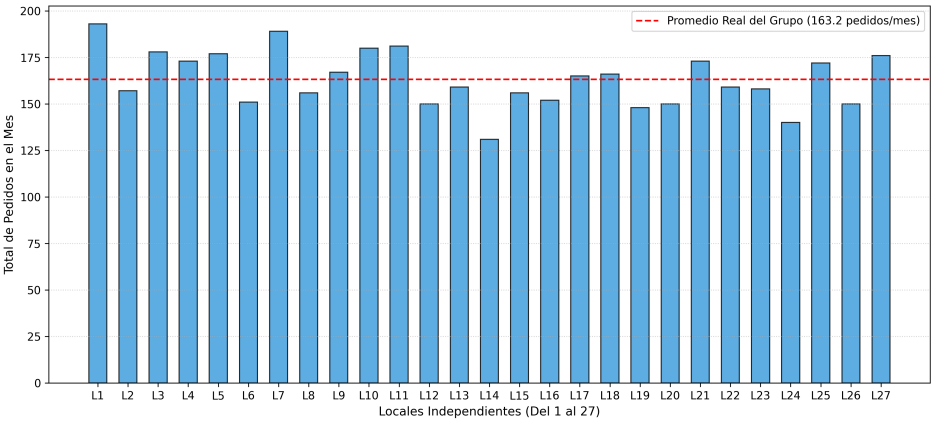



Figure 3.9: ¿Cómo se reparten los pedidos quitando las grandes franquicias?

Así nos despedimos de este gran capítulo. Nuestro primer capítulo usando simulaciones para entender las fortalezas y debilidades de un modelo estimador. De esta manera, espero dejar clara mi metodología, y que en los próximos capítulos podamos adentrarnos en los análisis de modelos más complejos, teniendo completamente claro en qué consiste una simulación.